

Capítulo 2: Introdução à Modelagem Matemática

Bioinformática para Biologia de Sistemas

Ney Lemke

DBF-Unesp

3 de janeiro de 2026

Sumário

- 1 Introdução
- 2 Tipos de Modelos
- 3 Construção de Modelos
- 4 Equações Diferenciais em Biologia
- 5 Sistemas de EDOs
- 6 Análise de Equilíbrio
- 7 Métodos Numéricos
- 8 Análise de Sensibilidade
- 9 Ajuste de Modelos a Dados
- 10 Estudo de Caso
- 11 Boas Práticas em Modelagem
- 12 Exercícios
- 13 Referências

2.1 Introdução à Modelagem Matemática

Objetivos de Aprendizagem

- Compreender o que são modelos matemáticos
- Aprender a construir modelos para sistemas biológicos
- Dominar técnicas de análise de modelos
- Aplicar modelagem a problemas reais

Definição: Modelo Matemático

Representação abstrata de um sistema real usando linguagem matemática, que permite fazer previsões quantitativas sobre o comportamento do sistema.

Por que Modelar Sistemas Biológicos?

Vantagens da Modelagem:

- Previsão de comportamento
- Teste de hipóteses *in silico*
- Otimização de experimentos
- Identificação de componentes chave
- Design racional de sistemas


Aplicações:

- Dinâmica de populações
- Vias metabólicas
- Redes regulatórias
- Farmacocinética
- Biologia sintética
- Medicina personalizada

Importante!

"All models are wrong, but some are useful— George Box

O Ciclo da Modelagem



Ciclo Iterativo

O processo é iterativo: modelos são refinados com base em novos dados experimentais

Classificação de Modelos

Por Natureza Matemática

- **Determinísticos:** resultado único para cada conjunto de condições
- **Estocásticos:** incorporam aleatoriedade e probabilidade

Por Dependência Temporal

- **Estáticos:** não mudam com o tempo (redes, equilíbrio)
- **Dinâmicos:** evolução temporal (EDOs, EDPs)

Por Escala

- **Microscópicos:** nível molecular/celular
- **Mesoscópicos:** populações celulares
- **Macroscópicos:** tecidos, órgãos, organismos

Modelos Contínuos vs Discretos

Modelos Contínuos

- Variáveis contínuas
- Equações diferenciais
- Concentrações
- Grande número de moléculas

Exemplo:

$$\frac{d[X]}{dt} = k_1 - k_2[X]$$

Modelos Discretos

- Contagem de moléculas
- Algoritmos estocásticos
- Eventos discretos
- Pequeno número de moléculas

Exemplo:

$$X(t+1) = X(t) + \text{prod} - \text{deg}$$

Quando usar cada tipo?

- Contínuo: >100 moléculas
- Discreto: <100 moléculas

Modelos Empíricos vs Mecanísticos

Empíricos

Baseados em dados

- Ajuste de curvas
- Regressão estatística
- Machine learning
- Pouca interpretação biológica

Vantagens:

- Simples e rápidos
- Bom ajuste aos dados

Desvantagens:

- Pouco poder preditivo

Mecanísticos

Baseados em mecanismos

- Representam processos reais
- Leis de conservação
- Princípios físico-químicos
- Interpretação biológica

Vantagens:

- Poder preditivo
- Extrapolação confiável

Desvantagens:

- Complexos

Etapas da Construção de Modelos

1. Definição do problema

- Objetivo claro
- Escopo bem definido
- Questões a responder

2. Identificação de variáveis

- Variáveis de estado
- Parâmetros
- Entradas e saídas

3. Formulação de equações

- Leis de conservação
- Cinéticas de reação
- Condições iniciais e de contorno

4. Análise e simulação

Exemplo: Modelo de Decaimento Radioativo

Sistema

Um isótopo radioativo decai espontaneamente ao longo do tempo

1. **Variável de estado:** $N(t)$ = número de núcleos no tempo t
2. **Hipótese:** Taxa de decaimento proporcional ao número de núcleos
3. **Equação:**

$$\frac{dN}{dt} = -\lambda N$$

4. **Solução analítica:**

$$N(t) = N_0 e^{-\lambda t}$$

onde $N_0 = N(0)$ é a condição inicial e λ é a constante de decaimento.

Implementação: Decaimento Radioativo

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.integrate import odeint
4
5 # Definir a EDO
6 def decay(N, t, lam):
7     """Taxa de variacao de N"""
8     return -lam * N
9
10 # Parametros
11 lambda_val = 0.5 # constante de decaimento
12 N0 = 100          # quantidade inicial
13 t = np.linspace(0, 10, 100)
14
15 # Resolver numericamente
```

Equações Diferenciais Ordinárias (EDOs)

Definição: EDO

Equação que relaciona uma função com suas derivadas em relação a uma variável independente (geralmente o tempo).

Forma Geral

$$\frac{d\mathbf{x}}{dt} = \mathbf{f}(\mathbf{x}, t, \mathbf{p})$$

onde:

- $\mathbf{x}$ = vetor de variáveis de estado
- t = tempo
- $\mathbf{p}$ = vetor de parâmetros
- $\mathbf{f}$ = função que define a dinâmica

Classificação de EDOs

Por Ordem

- **Primeira ordem:** $\frac{dx}{dt} = f(x, t)$
- **Segunda ordem:** $\frac{d^2x}{dt^2} = f(x, \frac{dx}{dt}, t)$
- **Ordem n :** derivadas até n -ésima ordem

Por Linearidade

- **Linear:** $\frac{dx}{dt} = ax + b$
- **Não-linear:** $\frac{dx}{dt} = ax^2 + bx$

Por Autonomia

- **Autônoma:** $\frac{dx}{dt} = f(x)$ (não depende explicitamente de t)
- **Não-autônoma:** $\frac{dx}{dt} = f(x, t)$

Exemplo: Crescimento Exponencial

Modelo Simples de Crescimento

Uma população cresce proporcionalmente ao seu tamanho:

$$\frac{dN}{dt} = rN$$

onde r é a taxa de crescimento per capita.

Solução analítica:

$$N(t) = N_0 e^{rt}$$

Se $r > 0$: crescimento

Se $r < 0$: decaimento

Se $r = 0$: estacionário

Tempo de Duplicação

$$t_2 = \frac{\ln 2}{r}$$

Exemplo: Crescimento Logístico

Modelo de Verhulst

População com capacidade de suporte limitada K :


$$\frac{dN}{dt} = rN \left(1 - \frac{N}{K} \right)$$

Solução analítica:

$$N(t) = \frac{KN_0 e^{rt}}{K + N_0(e^{rt} - 1)}$$

Comportamento:

- $N \rightarrow K$ quando $t \rightarrow \infty$
- Forma sigmoidal



Implementação: Crescimento Logístico

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.integrate import odeint
4
5 def logistic(N, t, r, K):
6     """Modelo de crescimento logístico"""
7     return r * N * (1 - N/K)
8
9 # Parametros
10 r = 0.5      # taxa de crescimento
11 K = 100      # capacidade de suporte
12 N0 = 10      # populacao inicial
13
14 # Tempo
15 t = np.linspace(0, 20, 200)
```


Sistemas Acoplados

Sistema Geral

Quando múltiplas variáveis interagem:

$$\frac{dx_1}{dt} = f_1(x_1, x_2, \dots, x_n, t)$$

$$\frac{dx_2}{dt} = f_2(x_1, x_2, \dots, x_n, t)$$

$$\vdots$$

$$\frac{dx_n}{dt} = f_n(x_1, x_2, \dots, x_n, t)$$

Notação vetorial:

dx

Exemplo: Modelo Predador-Presa (Lotka-Volterra)

Sistema

$$\begin{aligned}\frac{dV}{dt} &= \alpha V - \beta VP && \text{(Presas)} \\ \frac{dP}{dt} &= \delta\beta VP - \gamma P && \text{(Predadores)}\end{aligned}$$

onde:

- V = população de presas
- P = população de predadores
- α = taxa de crescimento das presas
- β = taxa de predação
- γ = taxa de morte dos predadores

Interpretação do Modelo Predador-Presa

Equação das Presas:

$$\frac{dV}{dt} = \underbrace{\alpha V}_{\text{crescimento}} - \underbrace{\beta VP}_{\text{predação}}$$

- Crescem exponencialmente sem predadores
- Perdem indivíduos por predação
- Taxa de predação $\propto$ encontros (VP)

Equação dos Predadores:

$$\frac{dP}{dt} = \underbrace{\delta \beta VP}_{\text{crescimento}} - \underbrace{\gamma P}_{\text{morte}}$$

- Crescem ao consumir presas
- Morrem naturalmente
- Dependem das presas para sobreviver

Importante!

Este sistema exhibe oscilações periódicas características!


Implementação: Lotka-Volterra

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.integrate import odeint
4
5 def lotka_volterra(y, t, alpha, beta, delta, gamma):
6     """Sistema Lotka-Volterra"""
7     V, P = y
8     dVdt = alpha*V - beta*V*P
9     dPdt = delta*beta*V*P - gamma*P
10    return [dVdt, dPdt]
11
12 # Parametros
13 alpha = 1.0
14 beta = 0.1
15 delta = 0.75
```

Retrato de Fase

```
1 # Retrato de fase
2 plt.figure()
3 plt.plot(sol[:, 0], sol[:, 1],
4          'g-', linewidth=2)
5 plt.plot(sol[0, 0], sol[0, 1],
6          'go', markersize=10,
7          label='Inicio')
8 plt.xlabel('Presas (V)')
9 plt.ylabel('Predadores (P)')
10 plt.title('Retrato de Fase')
11 plt.legend()
12 plt.grid(True)
13
14 # Campo vetorial
15 V = np.linspace(0, 20, 20)
16 P = np.linspace(0, 15, 20)
17 V_grid, P_grid = np.meshgrid(V, P)
18 dV, dP = lotka_volterra(
19     [V_grid, P_grid], 0,
20     alpha, beta, delta, gamma)
21 plt.quiver(V_grid, P_grid,
22            dV, dP, alpha=0.5)
```

Listing 4: Plano de fase



Características:

- Trajetórias fechadas
- Oscilações periódicas
- Centro estável

Pontos de Equilíbrio (Steady States)

Definição: Ponto de Equilíbrio

Estado no qual o sistema não muda com o tempo:

$$\frac{d\mathbf{x}}{dt} = 0 \quad \Rightarrow \quad \mathbf{f}(\mathbf{x}^*, t) = 0$$

Exemplo: Crescimento Logístico

$$\frac{dN}{dt} = rN \left(1 - \frac{N}{K} \right) = 0$$


Pontos de equilíbrio:

- $N_1^* = 0$ (extinção)
- $N_2^* = K$ (capacidade de suporte)

Estabilidade de Pontos de Equilíbrio

Classificação

- **Estável:** sistema retorna ao equilíbrio após perturbação
- **Instável:** sistema se afasta após perturbação
- **Marginalmente estável:** comportamento intermediário



Analise de Estabilidade Linear

Linearização em Torno do Equilíbrio

Para $\mathbf{x} = \mathbf{x}^* + \delta\mathbf{x}$ (pequena perturbação):

$$\frac{d\delta\mathbf{x}}{dt} = \mathbf{J}(\mathbf{x}^*)\delta\mathbf{x}$$

onde $\mathbf{J}$ é a matriz Jacobiana:

$$J_{ij} = \left. \frac{\partial f_i}{\partial x_j} \right|_{\mathbf{x}^*}$$

Critério de Estabilidade

O equilíbrio $\mathbf{x}^*$ é estável se todos os autovalores de $\mathbf{J}(\mathbf{x}^*)$ têm parte real negativa.

Exemplo: Análise do Crescimento Logístico

Modelo

$$\frac{dN}{dt} = f(N) = rN \left(1 - \frac{N}{K}\right)$$

Jacobiano (1D):

$$J = \frac{df}{dN} = r \left(1 - \frac{2N}{K}\right)$$

Nos pontos de equilíbrio:

- $N^* = 0$: $J(0) = r > 0 \Rightarrow$ instável
- $N^* = K$: $J(K) = -r < 0 \Rightarrow$ estável

Importante!

A população converge para a capacidade de suporte K

Analise de Estabilidade Computacional

```
1 import numpy as np
2 from scipy.linalg import eig
3
4 def jacobian_lotka_volterra(y, alpha, beta,
5                             delta, gamma):
6     """Calcula Jacobiano do sistema LV"""
7     V, P = y
8     J = np.array([
9         [alpha - beta*P, -beta*V],
10        [delta*beta*P, delta*beta*V - gamma]
11    ])
12     return J
13
14 # Ponto de equilibrio
15 V_eq = gamma / (delta * beta)
```

Por que Métodos Numéricos?

Limitações das Soluções Analíticas

- Maioria dos sistemas biológicos são não-lineares
- Poucos modelos têm solução analítica fechada
- Sistemas complexos requerem aproximação numérica

Métodos Numéricos Comuns

- **Euler:** simples, primeira ordem
- **Runge-Kutta (RK4):** preciso, quarta ordem
- **Métodos adaptativos:** passo variável (RK45, Dormand-Prince)
- **Métodos implícitos:** sistemas rígidos (BDF)

Método de Euler

Ideia Básica

Aproximar derivada por diferença finita:

$$\frac{dx}{dt} \approx \frac{x(t+h) - x(t)}{h}$$

$$x(t+h) = x(t) + h \cdot f(x(t), t)$$

Algoritmo:

1. Partir de x_0 em t_0
2. Calcular $x_1 = x_0 + h \cdot f(x_0, t_0)$
3. Repetir: $x_{n+1} = x_n + h \cdot f(x_n, t_n)$

Erro

Implementação do Método de Euler

```
1 def euler(f, x0, t):
2     """
3     Metodo de Euler para resolver EDOs
4     f: funcao dx/dt = f(x, t)
5     x0: condicao inicial
6     t: array de tempos
7     """
8     n = len(t)
9     x = np.zeros((n, len(x0)))
10    x[0] = x0
11
12    for i in range(n-1):
13        h = t[i+1] - t[i]
14        x[i+1] = x[i] + h * np.array(f(x[i], t[i]))
15
```

Método de Runge-Kutta de 4ª Ordem (RK4)

Ideia

Usar múltiplas avaliações da derivada para melhor aproximação

$$k_1 = f(x_n, t_n)$$

$$k_2 = f\left(x_n + \frac{h}{2}k_1, t_n + \frac{h}{2}\right)$$

$$k_3 = f\left(x_n + \frac{h}{2}k_2, t_n + \frac{h}{2}\right)$$

$$k_4 = f(x_n + hk_3, t_n + h)$$

$$x_{n+1} = x_n + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4)$$

Implementação do RK4

```
1 def rk4(f, x0, t):
2     """Metodo Runge-Kutta de 4a ordem"""
3     n = len(t)
4     x = np.zeros((n, len(x0)))
5     x[0] = x0
6
7     for i in range(n-1):
8         h = t[i+1] - t[i]
9         k1 = np.array(f(x[i], t[i]))
10        k2 = np.array(f(x[i] + h*k1/2, t[i] + h/2))
11        k3 = np.array(f(x[i] + h*k2/2, t[i] + h/2))
12        k4 = np.array(f(x[i] + h*k3, t[i] + h))
13
14        x[i+1] = x[i] + (h/6) * (k1 + 2*k2 + 2*k3 + k4)
15
```

Analise de Sensibilidade

Definição: Sensibilidade

Medida de como a saída de um modelo varia em resposta a mudanças nos parâmetros de entrada.

Por que é importante?

- Identificar parâmetros críticos
- Priorizar experimentos para estimar parâmetros
- Avaliar robustez do modelo
- Simplificar modelos complexos

Coeficiente de Sensibilidade

$$S_{x,p} = \frac{\partial x}{\partial p} \cdot \frac{p}{x} = \frac{\partial \ln x}{\partial \ln p}$$

Tipos de Análise de Sensibilidade

Local

- Variação em torno de um ponto nominal
- Derivadas parciais
- Rápida e analítica (quando possível)

Global

- Exploração de todo o espaço de parâmetros
- Métodos de amostragem (Monte Carlo, Sobol)
- Computacionalmente intensiva

Trade-off

Local: rápida mas limitada

Global: abrangente mas custosa

Analise de Sensibilidade Local

```
1 def sensitivity_local(model, params, param_names,
2                       perturbation=0.01):
3     """
4     Analise de sensibilidade local
5     """
6     baseline = model(params)
7     sensitivities = {}
8
9     for i, name in enumerate(param_names):
10        # Perturbar parametro
11        params_pert = params.copy()
12        params_pert[i] *= (1 + perturbation)
13
14        # Calcular saida perturbada
15        output_pert = model(params_pert)
```

Estimação de Parâmetros

Problema

Dados: $(t_1, y_1), (t_2, y_2), \dots, (t_n, y_n)$

Modelo: $\hat{y}(t; \mathbf{p})$

Objetivo: Encontrar $\mathbf{p}^*$ que melhor ajusta os dados

Função Objetivo

Mínimos quadrados:

$$\text{SSE}(\mathbf{p}) = \sum_{i=1}^n [y_i - \hat{y}(t_i; \mathbf{p})]^2$$

Objetivo: $\min_{\mathbf{p}} \text{SSE}(\mathbf{p})$

Métodos de Otimização

Ajuste de Curvas com scipy

```
1 from scipy.optimize import curve_fit
2
3 # Dados experimentais (com ruído)
4 t_data = np.linspace(0, 10, 20)
5 r_true, K_true = 0.5, 100
6 N_true = K_true / (1 + (K_true/10 - 1)*np.exp(-r_true*t_data
7     ))
8
9 # Modelo logístico
10 def logistic_model(t, r, K):
11     N0 = 10
12     return K / (1 + (K/N0 - 1)*np.exp(-r*t))
13
14 # Ajustar
```

Métricas de Qualidade do Ajuste

- **SSE**: Soma dos erros quadrados
- **R²**: Coeficiente de determinação (0 a 1)
- **RMSE**: Raiz do erro quadrático médio
- **AIC/BIC**: Critérios de informação (penalizam complexidade)

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

Atenção!

- **R²** alto não garante bom modelo
- Validar com dados independentes

Estudo de Caso: Dinâmica de Infecção Viral

Sistema

Modelo SIR (Susceptible-Infected-Recovered):

$$\begin{aligned}\frac{dS}{dt} &= -\beta \frac{SI}{N} \\ \frac{dI}{dt} &= \beta \frac{SI}{N} - \gamma I \\ \frac{dR}{dt} &= \gamma I\end{aligned}$$

onde:

- S = susceptíveis
- I = infectados
- R = recuperados

Numero Básico de Reprodução

Definição: R_0 (R-naught)

Numero médio de infecções secundárias causadas por um indivíduo infectado em uma população totalmente susceptível.

$$R_0 = \frac{\beta}{\gamma}$$

Interpretação

- $R_0 < 1$: epidemia se extingue
- $R_0 > 1$: epidemia se propaga
- $R_0 = 1$: limiar epidêmico

Implementação do Modelo SIR

```
1 def sir_model(y, t, beta, gamma):
2     """Modelo SIR"""
3     S, I, R = y
4     N = S + I + R
5     dSdt = -beta * S * I / N
6     dIdt = beta * S * I / N - gamma * I
7     dRdt = gamma * I
8     return [dSdt, dIdt, dRdt]
9
10 # Parametros
11 beta = 0.5    # taxa de transmissao (1/dia)
12 gamma = 0.1   # taxa de recuperacao (1/dia)
13 R0 = beta / gamma # R0 = 5
14
15 # Condições iniciais
```


Análise e Visualização

```
1 S, I, R = sol.T
2
3 # Plotar dinamica
4 plt.figure(figsize=(10, 6))
5 plt.plot(t, S, 'b-', label='Susceptíveis', linewidth=2)
6 plt.plot(t, I, 'r-', label='Infectados', linewidth=2)
7 plt.plot(t, R, 'g-', label='Recuperados', linewidth=2)
8 plt.xlabel('Tempo (dias)')
9 plt.ylabel('Numero de individuos')
10 plt.title(f'Modelo SIR ( $R_0 = {R0:.1f}$ )')
11 plt.legend()
12 plt.grid(True)
13
14 # Encontrar pico de infeccao
15 peak_idx = np.argmax(I)
```

Princípios de Modelagem

1. Simplicidade vs Realismo

- Comece simples, adicione complexidade gradualmente
- "Make things as simple as possible, but not simpler— Einstein
- Balanceie entre descrição acurada e tratabilidade

2. Validação

- Compare com dados experimentais
- Teste previsões em novos experimentos
- Valide em múltiplas escalas/condições

3. Documentação

- Documente hipóteses claramente
- Registre origem de parâmetros

Erros Frequentes

1. **Overfitting:** modelo complexo demais para os dados
2. **Parâmetros não-identificáveis:** múltiplas soluções
3. **Unidades inconsistentes:** sempre verifique dimensões
4. **Condições iniciais irrealistas:** valores negativos, etc.
5. **Extrapolação excessiva:** além do regime validado
6. **Ignorar incerteza:** sempre quantifique incerteza

Importante!

"Remember that all models are wrong; the practical question is how wrong do they have to be to not be useful— George Box

Ferramentas Computacionais

Python

- NumPy, SciPy
- Matplotlib, Seaborn
- PyDSTool
- Tellurium
- COBRApy (metabolismo)

R

- deSolve
- FME (fitting)
- ggplot2

MATLAB

- ode45, ode15s
- SimBiology
- Simbólico

Especializadas

- COPASI
- CellDesigner
- Virtual Cell
- BioNetGen

Exercícios - Parte 1

Questão 1: Modelo de Crescimento

Considere um modelo de crescimento com colheita constante:

$$\frac{dN}{dt} = rN \left(1 - \frac{N}{K} \right) - H$$

1. Encontre os pontos de equilíbrio
2. Analise a estabilidade para $H < rK/4$ e $H > rK/4$
3. Interprete biologicamente

Questão 2: Método Numérico

Implemente o método de Euler para resolver:

$$\frac{dy}{dt} = -y + \sin(t), \quad y(0) = 1$$

Questão 3: Sistema Acoplado

Considere o sistema de competição:

$$\begin{aligned}\frac{dN_1}{dt} &= r_1 N_1 \left(1 - \frac{N_1 + \alpha N_2}{K_1} \right) \\ \frac{dN_2}{dt} &= r_2 N_2 \left(1 - \frac{N_2 + \beta N_1}{K_2} \right)\end{aligned}$$

1. Implemente o modelo em Python
2. Encontre os pontos de equilíbrio
3. Simule para diferentes valores de α e β
4. O que acontece quando $\alpha\beta > 1$ vs $\alpha\beta < 1$?

Projeto: Modelo SIR com Vacinação

Estenda o modelo SIR para incluir vacinação:

$$\frac{dS}{dt} = -\beta \frac{SI}{N} - \nu S$$

$$\frac{dI}{dt} = \beta \frac{SI}{N} - \gamma I$$

$$\frac{dR}{dt} = \gamma I + \nu S$$

onde ν é a taxa de vacinação.

1. Implemente o modelo
2. Calcule o novo R_0 efetivo
3. Determine a taxa de vacinação necessária para controlar a epidemia ($R_0^{eff} < 1$)

Referências Principais

-  Strogatz S.H. (2018). *Nonlinear Dynamics and Chaos*, 2nd ed. CRC Press.
-  Edelstein-Keshet L. (2005). *Mathematical Models in Biology*. SIAM.
-  Britton N.F. (2003). *Essential Mathematical Biology*. Springer.
-  Murray J.D. (2002). *Mathematical Biology I: An Introduction*, 3rd ed. Springer.
-  Keener J., Sneyd J. (2009). *Mathematical Physiology*, 2nd ed. Springer.

Leitura Complementar

Livros Avançados

- Ellner S.P., Guckenheimer J. (2011). *Dynamic Models in Biology*
- Alon U. (2019). *An Introduction to Systems Biology*, 2nd ed.
- Klipp E. et al. (2016). *Systems Biology*, 2nd ed.

Recursos Online

- **Wolfram MathWorld:** <https://mathworld.wolfram.com>
- **MIT OCW:** Mathematical Biology course
- **Scipy Lecture Notes:** <https://scipy-lectures.org>

Tutoriais Python

- <https://scipy-cookbook.readthedocs.io>
- <https://python-numerics.github.io>

Obrigado!

Capítulo 2: Introdução à Modelagem Matemática

Próximo Capítulo:
Static Network Models

Dúvidas? Perguntas?