

Capítulo 3: Modelos de Redes Estáticas

Bioinformática para Biologia de Sistemas

Ney Lemke

DBF-Unesp

3 de janeiro de 2026

Sumário

- 1 Introdução
- 2 Fundamentos de Teoria dos Grafos
- 3 Propriedades Topológicas de Redes
- 4 Redes Biológicas
- 5 Análise de Controle Metabólico
- 6 Exercícios
- 7 Referências

Visão Geral do Capítulo

Objetivos de Aprendizagem

- Compreender os fundamentos de teoria dos grafos
- Analisar propriedades topológicas de redes biológicas
- Explorar modelos de redes small-world e scale-free
- Estudar tipos de redes biológicas e suas características
- Aplicar análise de controle metabólico (MCA)

Por que Estudar Redes Biológicas?

Redes são essenciais para:

- Entender organização e função de sistemas biológicos
- Identificar alvos terapêuticos e biomarcadores


O que são Redes Biológicas?

Definição: Rede Biológica

Uma rede biológica é uma representação matemática de interações entre componentes biológicos (genes, proteínas, metabólitos) como um grafo, onde nós representam entidades e arestas representam relações.

Características:

- Estrutura modular
- Hierarquia organizacional
- Robustez a perturbações
- Propriedades emergentes



Tipos de Redes Biológicas

Redes de Interação Proteica (PPI)

- Nós: proteínas
- Arestas: interações físicas
- Não-direcionadas
- Ex: complexos proteicos

Redes Regulatórias Gênicas

- Nós: genes/fatores de transcrição
- Arestas: regulação transcricional
- Direcionadas (ativação/repressão)
- Ex: circuitos genéticos

Redes Metabólicas

- Nós: metabólitos ou reações
- Arestas: conversões enzimáticas
- Direcionadas
- Ex: glicólise, ciclo de Krebs

Redes de Sinalização

- Nós: proteínas sinalizadoras
- Arestas: cascatas de sinalização
- Direcionadas
- Ex: vias MAPK, PI3K-AKT

Conceitos Básicos de Grafos


Definição: Grafo

Um grafo $G = (V, E)$ é composto por:

- V : conjunto de vértices (nós)
- E : conjunto de arestas (conexões) entre vértices


Grafo Não-Direcionado

Arestas sem direção: $(u, v) = (v, u)$



Grafo Direcionado (Dígrafo)

Arestas com direção: $(u, v) \neq (v, u)$




Representação de Grafos: Matriz de Adjacência

Definição: Matriz de Adjacência

Matriz A de dimensão $n \times n$ onde $n = |V|$:

$$A_{ij} = \begin{cases} 1 & \text{se existe aresta de } i \text{ para } j \\ 0 & \text{caso contrário} \end{cases}$$



Matriz de Adjacência:

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

Propriedades:

Representação de Grafos: Matriz de Incidência

Definição: Matriz de Incidência

Matriz B de dimensão $n \times m$ onde $n = |V|$ e $m = |E|$:

$$B_{ie} = \begin{cases} 1 & \text{se vértice } i \text{ é origem da aresta e} \\ -1 & \text{se vértice } i \text{ é destino da aresta e} \\ 0 & \text{caso contrário} \end{cases}$$

Vantagens

- Útil para representar grafos esparsos
- Facilita análise de fluxos em redes metabólicas
- Cada coluna representa uma reação bioquímica

Grau de um Vértice


Definição: Grau (Degree)

O grau de um vértice é o número de arestas conectadas a ele.

- **Grafo não-direcionado:** $k_i = \sum_j A_{ij}$
- **Grafo direcionado:**
 - In-degree: $k_i^{in} = \sum_j A_{ji}$ (arestas que chegam)
 - Out-degree: $k_i^{out} = \sum_j A_{ij}$ (arestas que saem)

Nó A: $k_A = 4$

Nós B,C,D,E: $k = 1$



Importante!

O grau médio da rede é:

Caminhos e Ciclos


Definição: Caminho

Sequência de vértices $v_1, v_2, \dots, v_k$ onde existe aresta entre v_i e v_{i+1} .

- **Comprimento:** número de arestas
- **Caminho simples:** sem repetição de vértices

Definição: Ciclo

Caminho fechado: $v_1 = v_k$



Caminho: 1-2-3-4


Importância Biológica

- Caminhos: vias de sinalização, rotas metabólicas

Componentes Conectados

Definição: Componente Conectado

Subconjunto máximo de vértices tal que existe um caminho entre qualquer par de vértices.



Componente 1 Componente 2 Componente 3

Importante!

Diâmetro e Comprimento Médio de Caminho

Definição: Distância entre Vértices

$d(u, v)$ = comprimento do menor caminho entre u e v (geodésica)

Definição: Diâmetro

Maior distância entre qualquer par de vértices:

$$D = \max_{u, v \in V} d(u, v)$$

Definição: Caminho Médio

$$L = \frac{1}{n(n-1)} \sum_{u \neq v} d(u, v)$$

Propriedade Small-World

Muitas redes biológicas têm:

- Diâmetro pequeno
- $L \propto \log(n)$
- Alcance rápido entre nós

Fenômeno Six Degrees

Na maioria das redes sociais e biológicas,
 $L \approx 6$

Criando e Analisando Grafos com NetworkX

```
1 import networkx as nx
2 import matplotlib.pyplot as plt
3
4 # Criar grafo nao-direcionado
5 G = nx.Graph()
6
7 # Adicionar nos e arestas
8 G.add_nodes_from([1, 2, 3, 4, 5])
9 G.add_edges_from([(1,2), (1,3), (2,3), (3,4), (4,5)])
10
11 # Propriedades basicas
12 print(f"Numero de nos: {G.number_of_nodes()}")
13 print(f"Numero de arestas: {G.number_of_edges()}")
14 print(f"Grau medio: {sum(dict(G.degree()).values())/G.
15         number_of_nodes()}")
16
17 # Calcular distancias
```

Análise de Matriz de Adjacência

```
1 import numpy as np
2 import networkx as nx
3
4 # Criar grafo de exemplo
5 G = nx.Graph()
6 G.add_edges_from([(1,2), (1,3), (2,3), (3,4)])
7
8 # Obter matriz de adjacencia
9 A = nx.adjacency_matrix(G).todense()
10 print("Matriz de Adjacencia:")
11 print(A)
12
13 # Calcular graus a partir da matriz
14 degrees = np.sum(A, axis=1)
15 print(f"\nGraus dos vertices: {degrees.T}")
16
17 # Matriz de adjacencia elevada ao quadrado
```

Distribuição de Graus

Definição: Distribuição de Graus

$P(k)$ = fração de nós na rede com grau k

Tipos de Distribuição:

Rede Aleatória (Erdős-Rényi)

- Distribuição de Poisson
- $P(k) = \frac{\langle k \rangle^k e^{-\langle k \rangle}}{k!}$
- A maioria dos nós tem grau próximo a $\langle k \rangle$

Rede Scale-Free

- Lei de potência (power-law)
- $P(k) \sim k^{-\gamma}$
- γ tipicamente entre 2 e 3
- Presença de hubs (nós altamente conectados)


Importante!

A maioria das redes biológicas segue distribuição scale-free


Visualizando Distribuições de Grau

Rede Scale-Free (Power-law)

Rede Aleatória (Poisson)



Maioria dos nós com grau similar




Coeficiente de Agrupamento (Clustering)

Definição: Coeficiente de Agrupamento Local

Mede a fração de pares de vizinhos de um nó que também são conectados:

$$C_i = \frac{2E_i}{k_i(k_i - 1)}$$

onde E_i = número de arestas entre vizinhos de i



Definição: Coeficiente Global

$$C = \frac{1}{n} \sum_{i=1}^n C_i$$

Importante!

Redes Small-World (Watts-Strogatz)


Características:

- Alto coeficiente de agrupamento (como rede regular)
- Pequeno caminho médio (como rede aleatória)
- $C \gg C_{random}$
- $L \approx L_{random}$

Modelo WS

1. Começar com anel regular
2. Reconectar cada aresta com probabilidade p
3. $p \in [0, 1]$: regular $\rightarrow$ aleatória

Small-World



Redes Scale-Free (Barabási-Albert)

Modelo de Ligação Preferencial (Preferential Attachment)

1. Começar com pequeno número de nós m_0
2. Adicionar novo nó com m arestas
3. Conectar a nós existentes com probabilidade:

$$\Pi(k_i) = \frac{k_i}{\sum_j k_j}$$

4. “Rico fica mais rico” (hubs atraem mais conexões)

Resultados:

- $P(k) \sim k^{-3}$

Exemplos Biológicos


- Redes de interação proteica
- Redes metabólicas

Motivos de Rede (Network Motifs)


Definição: Motivo de Rede

Padrões de interconexão recorrentes que aparecem significativamente mais frequentes que em redes aleatórias.


Feed-forward Loop



Bi-fan



Feedback Loop



Funções Biológicas

- **Feed-forward:** filtro de ruído, detecção de persistência
- **Feedback positivo:** switch biestável, memória


Nós Hub e Vulnerabilidade

Definição: Hub

Nó com grau muito maior que a média da rede ($k_i \gg \langle k \rangle$)

Propriedades:

- Centrais para conectividade
- Alvos de drogas e terapias
- Remoção causa fragmentação
- Evolutivamente conservados



Importante!

Redes scale-free são robustas a falhas aleatórias mas vulneráveis a ataques direcionados

Calculando Propriedades de Rede com NetworkX

```
1 import networkx as nx
2 import numpy as np
3
4 # Criar rede scale-free (Barabasi-Albert)
5 G = nx.barabasi_albert_graph(n=100, m=2)
6
7 # Distribuicao de graus
8 degrees = [G.degree(n) for n in G.nodes()]
9 print(f"Grau medio: {np.mean(degrees):.2f}")
10 print(f"Grau maximo: {max(degrees)}")
11
12 # Coeficiente de agrupamento
13 C_global = nx.average_clustering(G)
14 print(f"Clustering global: {C_global:.3f}")
15
16 # Caminho medio
17 if nx.is_connected(G):
```

Gerando Diferentes Modelos de Rede

```
1 import networkx as nx
2 import matplotlib.pyplot as plt
3
4 # 1. Rede Aleatoria (Erdos-Renyi)
5 G_random = nx.erdos_renyi_graph(n=50, p=0.1)
6
7 # 2. Rede Small-World (Watts-Strogatz)
8 G_sw = nx.watts_strogatz_graph(n=50, k=4, p=0.3)
9
10 # 3. Rede Scale-Free (Barabasi-Albert)
11 G_sf = nx.barabasi_albert_graph(n=50, m=2)
12
13 # Comparar propriedades
14 models = [G_random, G_sw, G_sf]
15 names = ['Random', 'Small-World', 'Scale-Free']
16
17 for G, name in zip(models, names):
```


Redes de Interação Proteína-Proteína (PPI)

Características:

- Nós: proteínas
- Arestas: interações físicas
- Não-direcionadas
- Scale-free
- Modularidade alta

Detecção Experimental:

- Yeast two-hybrid (Y2H)
- Affinity purification MS
- Protein arrays
- Co-immunoprecipitation



Rede PPI


Aplicações:

- Predição de função
- Identificação de complexos
- Descoberta de alvos

Redes Metabólicas

Duas Representações Principais

1. **Rede de metabólitos:** nós = metabólitos, arestas = reações
2. **Rede de reações:** nós = reações, arestas = metabólitos compartilhados



Via Metabólica

Importante!

Redes metabólicas são altamente conservadas entre espécies!


Redes Regulatórias Gênicas (GRN)

Componentes:

- Genes alvos
- Fatores de transcrição (TF)
- Elementos regulatórios (promotores)
- Interações de ativação/repressão

Propriedades:

- Direcionadas
- Hierárquicas
- Motivos regulatórios
- Feed-forward loops
- Auto-regulação




+ ativação, - repressão

Exemplo: Circuito Repressilator

Redes de Sinalização Celular

Características

- Transmissão de sinais extracelulares para resposta intracelular
- Cascatas de fosforilação (quinases)
- Amplificação de sinal
- Cross-talk entre vias
- Direcionadas e dinâmicas



Bases de Dados de Redes Biológicas

Redes de Interação Proteica

- **STRING**: <https://string-db.org>
- **BioGRID**:
<https://thebiogrid.org>
- **IntAct**:
<https://www.ebi.ac.uk/intact>
- **HPRD**: Human Protein Reference Database

Redes Metabólicas

- **KEGG**:
<https://www.genome.jp/kegg>
- **Reactome**: <https://reactome.org>

Redes Regulatórias

- **RegulonDB**: E. coli
- **TRANSFAC**: fatores de transcrição
- **ENCODE**: elementos regulatórios

Redes de Sinalização

- **KEGG Pathway**
- **NetPath**: vias de sinalização
- **Signalink**: cross-talk

Acessando Bases de Dados com Python

```
1 # Exemplo: Baixar rede PPI do STRING
2 import requests
3 import networkx as nx
4
5 # Parametros
6 species = '9606' # Homo sapiens
7 gene = 'TP53'
8 score_threshold = 700 # confianca minima
9
10 # Requisicao API
11 url = f'https://string-db.org/api/json/network?identifiers={gene
12         }&species={species}&required_score={score_threshold}'
13 response = requests.get(url)
14 data = response.json()
15
16 # Construir grafo
17 G = nx.Graph()
```


Exemplo: Rede de Interação de TP53

Gene TP53 (p53):

- Supressor tumoral
- “Guardião do genoma”
- Hub na rede PPI humana
- Interage com > 100 proteínas
- Mutado em $> 50\%$ dos cânceres

Principais Parceiros:

- MDM2 (regulação negativa)
- ATM, ATR (sensores de dano)
- p21 (ciclo celular)
- BAX, PUMA (apoptose)



Introdução à Análise de Controle Metabólico (MCA)

Definição: MCA (Metabolic Control Analysis)

Teoria quantitativa que analisa como mudanças em parâmetros individuais (atividade enzimática, concentrações) afetam propriedades sistêmicas (fluxos, concentrações).

Questões Fundamentais

- Qual enzima controla o fluxo em uma via metabólica?
- Como perturbações locais afetam o sistema global?
- Onde devemos intervir terapeuticamente?
- Como prever efeitos de mutações ou drogas?

Desenvolvida por

Henrik Kacser, Jim Burns (1973) e Reinhart Heinrich, Tom Rapoport (1974)

Coeficientes de Controle

Definição: Coeficiente de Controle de Fluxo

Mede como mudança na atividade da enzima i afeta o fluxo J :

$$C_i^J = \frac{\partial J/J}{\partial E_i/E_i} = \frac{\partial \ln J}{\partial \ln E_i}$$

Elasticidade normalizada do fluxo em relação à enzima.

Definição: Coeficiente de Controle de Concentração

Mede como mudança na atividade da enzima i afeta a concentração de metabólito S :

$$C_i^S = \frac{\partial S/S}{\partial E_i/E_i} = \frac{\partial \ln S}{\partial \ln E_i}$$

Coeficientes de Elasticidade

Definição: Elasticidade

Propriedade local que mede sensibilidade da taxa de reação v_i a mudanças em metabólito S :

$$\epsilon_S^{v_i} = \frac{\partial v_i / v_i}{\partial S / S} = \frac{\partial \ln v_i}{\partial \ln S}$$

Interpretação

- $\epsilon > 0$: S ativa a reação (substrato ou ativador)
- $\epsilon < 0$: S inibe a reação (inibidor)
- $|\epsilon| > 1$: alta sensibilidade (cooperatividade)
- $|\epsilon| < 1$: baixa sensibilidade

Teoremas de Soma

Importante!

Os coeficientes de controle obedecem restrições matemáticas fundamentais!

Teorema da Soma para Controle de Fluxo

Para uma via em estado estacionário:

$$\sum_{i=1}^n C_i^J = 1$$

O controle total do fluxo é distribuído entre todas as enzimas.

Teorema da Soma para Controle de Concentração

Para metabólito intermediário S :

Teorema da Conectividade

Relaciona Controle e Elasticidade

Para metabólito intermediário S :

$$\sum_{i=1}^n C_i^J \varepsilon_S^{v_i} = 0$$


Para reações consecutivas $v_1 \rightarrow S \rightarrow v_2$:

$$C_1^J \varepsilon_S^{v_1} + C_2^J \varepsilon_S^{v_2} = 0$$

Interpretação

- Liga propriedades locais (elasticidades) a globais (controle)
- Permite calcular coeficientes de controle a partir de elasticidades

Exemplo: Via Linear Simples



Estado estacionário: $v_1 = v_2 = v_3 = J$ (fluxo constante)

Usando Teoremas de MCA

$$C_1^J + C_2^J + C_3^J = 1 \quad (\text{Soma})$$

$$C_1^J \varepsilon_{S_1}^{v_1} + C_2^J \varepsilon_{S_1}^{v_2} = 0 \quad (\text{Conectividade para } S_1)$$

$$C_2^J \varepsilon_{S_2}^{v_2} + C_3^J \varepsilon_{S_2}^{v_3} = 0 \quad (\text{Conectividade para } S_2)$$

Cálculo de Coeficientes de Controle

Para via linear: $X_0 \xrightarrow{v_1} S_1 \xrightarrow{v_2} S_2 \xrightarrow{v_3} X_1$

Sistema de Equações

Supondo v_1 não depende de S_1 e v_3 não depende de S_2 :


$$\begin{aligned}\varepsilon_{S_1}^{v_1} &= 0, & \varepsilon_{S_2}^{v_3} &= 0 \\ C_1^J + C_2^J + C_3^J &= 1 \\ C_2^J \varepsilon_{S_1}^{v_2} &= 0 \quad \Rightarrow \quad C_2^J = 0 \text{ ou } \varepsilon_{S_1}^{v_2} = \infty\end{aligned}$$

Se todas elasticidades são similares

Aproximação: controle distribuído igualmente

$$C_1^J \approx C_2^J \approx C_3^J \approx \frac{1}{3}$$

Exemplo Numérico: Cálculo de MCA



Cinética:

$$v_1 = \frac{10 \cdot A}{5 + A}, \quad A = 10 \text{ mM (fixo)}$$

$$v_2 = \frac{8 \cdot B}{4 + B}$$

Estado estacionário: $v_1 = v_2 = J$

Passo 1: Encontrar B no estado estacionário

$$\frac{10 \times 10}{5 + 10} = \frac{8 \times B}{4 + B} \quad \Rightarrow \quad B \approx 5.7 \text{ mM}$$

Fluxo: $J = 6.67 \text{ mM/min}$

Continuação: Exemplo Numérico

Passo 3: Aplicar teoremas

Conectividade para B :

$$C_1^J \times 0 + C_2^J \times 0.41 = 0 \quad \Rightarrow \quad C_2^J = 0$$

Teorema da soma:

$$C_1^J + C_2^J = 1 \quad \Rightarrow \quad C_1^J = 1$$

Importante!

Resultado: $C_1^J = 1$, $C_2^J = 0$

Interpretação:

- A primeira enzima E_1 tem controle total do fluxo!
- A segunda enzima E_2 não controla o fluxo.

Simulando MCA com Python

```
1 import numpy as np
2 from scipy.optimize import fsolve
3
4 # Definir as taxas de reacao
5 def v1(A, Vmax1=10, Km1=5):
6     return Vmax1 * A / (Km1 + A)
7
8 def v2(B, Vmax2=8, Km2=4):
9     return Vmax2 * B / (Km2 + B)
10
11 # Encontrar estado estacionario (v1 = v2)
12 A_fixed = 10
13 def steady_state(B):
14     return v1(A_fixed) - v2(B)
15
16 B_ss = fsolve(steady_state, 5)[0]
17 J_ss = v2(B_ss)
```


Calculando Coeficientes de Controle Numericamente

```
1 # Metodo de perturbacao numerica
2 def calculate_flux_control_coefficient(enzyme_idx, delta=0.01):
3     """Calcula  $C_i^J$  por perturbacao numerica"""
4     # Estado base
5     if enzyme_idx == 1:
6         Vmax1_base = 10
7         B_ss_base = fsolve(lambda B: v1(A_fixed, Vmax1_base) - v2
8                               (B), 5)[0]
9         J_base = v2(B_ss_base)
10
11     # Perturbar E1
12     Vmax1_pert = Vmax1_base * (1 + delta)
13     B_ss_pert = fsolve(lambda B: v1(A_fixed, Vmax1_pert) - v2
14                          (B), 5)[0]
15     J_pert = v2(B_ss_pert)
16
17 elif enzyme_idx == 2:
```

Exercícios - Parte 1: Teoria dos Grafos

Questão 1: Matriz de Adjacência

Dada a matriz de adjacência abaixo, desenhe o grafo correspondente e calcule:

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

1. O grau de cada vértice
2. O grau médio da rede
3. O número de triângulos (ciclos de comprimento 3)

Questão 2: Caminho e Diâmetro

Exercícios - Parte 2: Propriedades de Rede

Questão 3: Coeficiente de Agrupamento

Para um nó com grau $k = 4$ que tem 3 arestas entre seus vizinhos, calcule o coeficiente de agrupamento local C_i .

Questão 4: Distribuição de Graus

Uma rede tem 100 nós com a seguinte distribuição de graus:

- 60 nós com grau 2
- 30 nós com grau 3
- 8 nós com grau 5
- 2 nós com grau 10

Calcule:

1. O grau médio $\langle k \rangle$

Exercícios - Parte 3: NetworkX

Questão 5: Implementação

Escreva código Python usando NetworkX para:

1. Gerar uma rede Barabási-Albert com $n = 50$ nós e $m = 2$
2. Calcular e plotar a distribuição de graus
3. Identificar os top 3 hubs (maior grau)
4. Calcular o coeficiente de agrupamento global
5. Comparar com rede aleatória Erdős-Rényi de mesmo tamanho

Questão 6: Robustez

Simule a remoção de nós (aleatória vs. direcionada aos hubs) em uma rede scale-free. Analise como o tamanho do componente gigante varia. Qual estratégia fragmenta mais rapidamente a rede?

Exercícios - Parte 4: MCA

Questão 7: Elasticidade

Para a reação com cinética de Michaelis-Menten:

$$v = \frac{100 \cdot S}{10 + S}$$

Calcule a elasticidade ε_S^v quando:

1. $[S] = 5 \text{ mM}$
2. $[S] = 10 \text{ mM} (= K_M)$
3. $[S] = 50 \text{ mM}$

Questão 8: Teorema da Soma

Em uma via com 5 enzimas, os coeficientes de controle de fluxo são: $C_1^J = 0.4$, $C_2^J = 0.3$, $C_3^J = 0.2$, $C_4^J = 0.05$

Exercícios - Parte 5: Aplicação

Projeto Prático

Escolha uma via metabólica (ex: glicólise, ciclo de Krebs) e:

1. Construa o grafo da via com NetworkX
2. Analise propriedades topológicas (grau, clustering, centralidade)
3. Identifique possíveis enzimas regulatórias baseado em análise de rede
4. Pesquise na literatura dados de MCA para esta via
5. Compare previsões topológicas com resultados experimentais de MCA

Questão 9: Bases de Dados

Use a API do STRING para baixar a rede PPI de um gene de interesse. Analise:

- Quantos parceiros diretos?
- O gene é um hub?

Referências Principais

-  Barabási A.L. (2016). *Network Science*. Cambridge University Press. Disponível em: <http://networksciencebook.com>
-  Alon U. (2019). *An Introduction to Systems Biology: Design Principles of Biological Circuits*, 2nd ed. Chapman & Hall/CRC.
-  Klipp E. et al. (2016). *Systems Biology: A Textbook*, 2nd ed. Wiley-VCH.
-  Fell D. (1997). *Understanding the Control of Metabolism*. Portland Press.
-  Heinrich R., Schuster S. (1996). *The Regulation of Cellular Systems*. Chapman & Hall.

Livros

- Newman M.E.J. (2018). *Networks*, 2nd ed. Oxford University Press.
- Voit E.O. (2017). *A First Course in Systems Biology*, 2nd ed.
- Palsson B.O. (2015). *Systems Biology: Properties of Reconstructed Networks*. Cambridge.

Artigos Fundamentais

- Barabási A.L., Albert R. (1999). Emergence of scaling in random networks. *Science* 286:509-512.
- Watts D.J., Strogatz S.H. (1998). Collective dynamics of small-world networks. *Nature* 393:440-442.
- Kacser H., Burns J.A. (1973). The control of flux. *Symp. Soc. Exp. Biol.* 27:65-104.

Ferramentas e Software

- **NetworkX**: <https://networkx.org>
- **Cytoscape**: <https://cytoscape.org> (visualização de redes)
- **igraph**: <https://igraph.org> (R e Python)
- **Gephi**: <https://gephi.org> (análise interativa)

Bases de Dados

- **STRING**: <https://string-db.org>
- **KEGG**: <https://www.genome.jp/kegg>
- **Reactome**: <https://reactome.org>
- **BioGRID**: <https://thebiogrid.org>

Obrigado!

Capítulo 3: Modelos de Redes Estáticas

Próximo Capítulo:
Modelos de Redes Dinâmicas e Simulação

Dúvidas? Perguntas?