

Capítulo 6: Sistemas Gênicos

Bioinformática para Biologia de Sistemas

Ney Lemke


DBF-Unesp

16 de janeiro de 2026

Sumário

- 1 Dogma Central da Biologia Molecular
- 2 Características do DNA
- 3 Regulação Gênica
- 4 Tipos de RNA
- 5 Medição de Expressão Gênica
- 6 Localização de Genes
- 7 GenBank
- 8 Análise Integrada
- 9 Estudos de Caso
- 10 Exercícios
- 11 Referências

6.1 Dogma Central da Biologia Molecular



Importante!

O fluxo de informação genética segue a direção: DNA $\rightarrow$ RNA $\rightarrow$ Proteína

Exceção: Retrovírus

Transcriptase reversa: RNA $\rightarrow$ DNA

Visão Geral dos Sistemas Gênicos

Objetivos de Aprendizagem

- Compreender a estrutura e organização dos genes
- Entender os mecanismos de regulação gênica
- Conhecer os diferentes tipos de RNA e suas funções
- Aprender técnicas de medição de expressão gênica
- Explorar bancos de dados genômicos (GenBank)


Definição: Gene

Unidade fundamental da hereditariedade: sequência de DNA que codifica uma molécula funcional (RNA ou proteína) e inclui regiões regulatórias.

6.2 Características do DNA (DNA Features)

Elementos Estruturais:

- Promotor
- Região codificante (ORF)
- Íntrons e éxons
- UTRs (5' e 3')
- Terminador
- Enhancers/Silencers



Procariotos vs Eucariotos

- **Procariotos:** genes sem íntrons, operons
- **Eucariotos:** íntrons, splicing alternativo

Promotores e Elementos Regulatórios

Promotor

Região onde a RNA polimerase se liga para iniciar a transcrição

Elementos em Procariotos:

- **-10 box** (Pribnow box):
TATAAT
- **-35 box**:
TTGACA
- **Operador**: controle negativo

Elementos em Eucariotos:

- **TATA box** (-25):
TATAAA
- **CAAT box** (-75)
- **GC box**
- **Enhancers** (distantes)

5' -- [Enhancer] -- [CAAT] -- [TATA] -- [+1] -- Gene -- 3'

Open Reading Frame (ORF)

Definição: ORF

Sequência contínua de códons entre um códon de início (ATG) e um códon de parada (TAA, TAG, TGA), sem códons de parada internos.

Exemplo

5'-ATG GCT AAA TGG CCA TAA-3'

Met-Ala-Lys-Trp-Pro-STOP

ORF: 15 nucleotídeos = 5 códons

Identificação de ORFs

Critérios:

- Começa com ATG (códon de início)
- Termina com TAA, TAG, TGA (códon de parada)

Busca de ORFs Computacional

```
1 def find_orfs(sequence, min_length=100):
2     """
3     Encontra ORFs em uma sequencia de DNA
4     """
5     start_codon = "ATG"
6     stop_codons = ["TAA", "TAG", "TGA"]
7     orfs = []
8
9     # Para cada frame (0, 1, 2)
10    for frame in range(3):
11        for i in range(frame, len(sequence)-2, 3):
12            codon = sequence[i:i+3]
13
14            # Encontrou inicio
15            if codon == start_codon:
16                # Procurar stop codon
17                for j in range(i+3, len(sequence)-2, 3):
```

6.3 Regulação Gênica

Níveis de Regulação

1. **Transcricional:** controle da síntese de RNA
2. **Pós-transcricional:** splicing, estabilidade do mRNA
3. **Traducional:** controle da síntese proteica
4. **Pós-traducional:** modificações, degradação
5. **Epigenética:** metilação, acetilação de histonas

Importante!


A regulação da expressão gênica permite:

- Resposta a sinais ambientais
- Diferenciação celular
- Desenvolvimento embrionário

Regulação Transcricional em Procariotos

Exemplo: Operon lac (Lactose)

Sistema clássico de regulação negativa e positiva



- **Sem lactose:** repressor LacI bloqueia transcrição
- **Com lactose:** lactose liga a LacI, liberando operador


Regulação Transcricional em Eucariotos

Fatores de Transcrição:

- Ativadores
- Repressores
- Mediadores
- Remodeladores de cromatina

Estrutura da Cromatina:

- Eucromatina (aberta)
- Heterocromatina (fechada)
- Nucleossomos



Modelo Matemático de Regulação Gênica

Equação de Hill

Modelo para regulação cooperativa:

$$\frac{d[mRNA]}{dt} = \frac{V_{max}[TF]^n}{K_d^n + [TF]^n} - \delta[mRNA]$$

onde:

- $[TF]$ = concentração do fator de transcrição
- n = coeficiente de Hill (cooperatividade)
- K_d = constante de dissociação
- δ = taxa de degradação do mRNA

Interpretação de n

Simulação de Regulação Gênica

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 def hill_function(TF, Vmax, Kd, n):
5     """Funcao de Hill para regulacao genica"""
6     return Vmax * TF**n / (Kd**n + TF**n)
7
8 # Parametros
9 Vmax = 100
10 Kd = 10
11 TF = np.linspace(0, 50, 200)
12
13 # Plotar diferentes cooperatividades
14 plt.figure(figsize=(10, 6))
15 for n in [1, 2, 4, 8]:
16     mRNA = hill_function(TF, Vmax, Kd, n)
17     plt.plot(TF, mRNA, linewidth=2, label=f'n = {n}')
```

6.4-6.6 Tipos de RNA

Classificação Funcional

RNAs Codificantes:

- **mRNA:** mensageiro (proteínas)

RNAs Não-codificantes:


- **rRNA:** ribossomal (estrutura, catálise)
- **tRNA:** transferência (adaptador)

RNAs Regulatórios:

- **miRNA:** microRNA (silenciamento)
- **siRNA:** RNA interferente (degradação)
- **lncRNA:** longo não-codificante (regulação cromossômica)
- **snoRNA:** nucleolar pequeno (modificação de rRNA)

6.4 RNA Mensageiro (mRNA)


Estrutura do mRNA em Eucariotos



Elementos Funcionais:

- **5' Cap:** proteção, reconhecimento para tradução
- **5' UTR:** regulação traducional
- **CDS:** sequência codificante (Coding Sequence)
- **3' UTR:** estabilidade, localização
- **Poly(A):** estabilidade, exportação nuclear


Processamento do mRNA em Eucariotos



6.5 RNA de Transferência (tRNA)

Estrutura em Folha de Trevo:

- Braço aceptor (3' CCA)
- Braço D
- Braço anticódon
- Braço T Ψ C
- Braço variável



Função:

- Transporta aminoácidos
- Reconhece códons via anticódon
- Adaptador molecular

Wobble Pairing

Flexibilidade na 3ª posição do códon

6.6 RNA Ribossomal (rRNA)

Componente Estrutural dos Ribossomos

Organismo	Subunidade	rRNA	Proteínas
Procarioto	30S	16S	21
	50S	23S, 5S	31
Eucarioto	40S	18S	33
	60S	28S, 5.8S, 5S	49

Funções:

- Estrutura do ribossomo
- Atividade peptidil-transferase
- Ligação de tRNA
- Translocação

Importante!

rRNA é uma **ribozima**: RNA com atividade catalítica!

RNAs Regulatórios: microRNA (miRNA)

Biogênese do miRNA

1. **Transcrição:** pri-miRNA (longo, hairpin)
2. **Processamento nuclear:** Drosha → pre-miRNA (~70 nt)
3. **Exportação:** Exportina-5
4. **Processamento citoplasmático:** Dicer → miRNA maduro (~22 nt)
5. **RISC:** complexo de silenciamento

Mecanismo de Ação

- **Pareamento perfeito:** clivagem do mRNA-alvo
- **Pareamento imperfeito:** repressão traducional
- Um miRNA pode regular centenas de mRNAs

6.7 Medição de Expressão Gênica

Técnicas Principais

Nível de mRNA:

- Northern blot
- RT-PCR / qPCR
- Microarrays
- RNA-seq
- Single-cell RNA-seq

Nível de Proteína:

- Western blot
- Imunofluorescência
- Espectrometria de massa
- Flow cytometry

Importante!

mRNA $\neq$ Proteína sempre!

Regulação pós-transcricional e pós-traducional

Microarrays de DNA

Princípio:

1. Sondas fixadas em chip
2. Hibridização de cDNA marcado
3. Detecção fluorescente
4. Análise de intensidade

Aplicações:

- Perfil de expressão global
- Comparação de condições
- Classificação de amostras
- Descoberta de genes



Microarray

RNA-seq: Sequenciamento de RNA

Vantagens sobre Microarrays

- Maior faixa dinâmica
- Sem necessidade de sondas pré-definidas
- Detecção de novos transcritos
- Resolução de nucleotídeo único
- Identificação de variantes de splicing
- Quantificação absoluta (não relativa)

Pipeline RNA-seq

1. Extração de RNA
2. Preparação de biblioteca (cDNA)
3. Sequenciamento (Illumina, PacBio, etc.)

Análise de Dados de RNA-seq

```
1 import pandas as pd
2 import numpy as np
3 from scipy import stats
4
5 # Carregar contagens (genes x amostras)
6 counts = pd.read_csv('gene_counts.csv', index_col=0)
7
8 # Normalizar (TPM, RPKM, ou DESeq2)
9 def tpm_normalize(counts, gene_lengths):
10     """Normalize para TPM (Transcripts Per Million)"""
11     # Reads per kilobase
12     rpk = counts / (gene_lengths / 1000)
13     # Scaling factor
14     scaling_factor = rpk.sum() / 1e6
15     tpm = rpk / scaling_factor
16     return tpm
17
```

Visualização: Volcano Plot

```
1 import matplotlib.pyplot as plt
2
3 # Calcular -log10(p-value)
4 neg_log_p = -np.log10(p_val)
5
6 # Criar volcano plot
7 plt.figure(figsize=(10, 8))
8 plt.scatter(log_fc, neg_log_p, alpha=0.5, s=10)
9
10 # Threshold lines
11 plt.axhline(y=-np.log10(0.05), color='r',
12             linestyle='--', label='p = 0.05')
13 plt.axvline(x=-1, color='b', linestyle='--')
14 plt.axvline(x=1, color='b', linestyle='--',
15             label='|log2 FC| = 1')
16
17 # Destacar genes significativos
```

6.8 Localização de Genes (Gene Localization)

Predição de Genes *Ab Initio*

Métodos computacionais que identificam genes baseando-se apenas na sequência de DNA:

- Busca de ORFs
- Detecção de sinais (promotores, splice sites)
- Modelos de Markov Ocultos (HMM)
- Redes neurais

Predição Baseada em Evidências

Usa dados experimentais:

- Alinhamento de ESTs (Expressed Sequence Tags)
- Alinhamento de proteínas homólogas
- Dados de RNA-seq

Ferramentas de Predição de Genes

Procariotos:

- Prodigal
- GeneMark
- Glimmer
- RAST

Eucariotos:

- Augustus
- GenScan
- SNAP
- MAKER (pipeline)
- Braker

Características

- Genes densos
- Poucos íntrons
- Operons
- Mais simples

Desafios

- Íntrons
- Splicing alternativo
- Genes esparsos
- DNA repetitivo

Exemplo: Usando BioPython para Anotação

```
1 from Bio import SeqIO
2 from Bio.SeqUtils import GC
3
4 def annotate_sequence(fasta_file):
5     """Anotacao basica de sequencia"""
6     for record in SeqIO.parse(fasta_file, "fasta"):
7         seq = record.seq
8         print(f"ID: {record.id}")
9         print(f"Comprimento: {len(seq)} bp")
10        print(f"GC%: {GC(seq):.2f}%")
11
12        # Buscar ORFs em todas as 6 frames
13        for strand, nuc in [(+1, seq), (-1, seq.
14            reverse_complement())]:
15            for frame in range(3):
16                length = 3 * ((len(seq) - frame) // 3)
17                for pro in nuc[frame:frame+length].translate().
```

GenBank: Banco de Dados de Sequências

O que é GenBank?

- Banco de dados público do NCBI (National Center for Biotechnology Information)
- Coleção abrangente de sequências de DNA
- Anotações de genes, proteínas, características
- Atualizado diariamente
- Livre acesso

Estatísticas (2024)

- >350 milhões de sequências
- >10 trilhões de pares de bases
- Crescimento exponencial

Formato de Arquivo GenBank

Estrutura

```
LOCUS      NM_000518      5510 bp      mRNA
DEFINITION Homo sapiens hemoglobin beta
ACCESSION  NM_000518
VERSION    NM_000518.5
ORGANISM   Homo sapiens
FEATURES             Location/Qualifiers
     gene             1..5510
                     /gene="HBB"
     CDS              51..495
                     /product="hemoglobin beta"
                     /translation="MVHLTPEEKSAVTAL..."
ORIGIN
      1 acatttgctt ctgacacaac tgtgtttcact agcaacctca
```


Acessando GenBank com BioPython

```
1 from Bio import Entrez, SeqIO
2
3 # Sempre fornecer email
4 Entrez.email = "seu_email@example.com"
5
6 # Buscar por gene
7 def search_genbank(query, max_results=10):
8     """Busca no GenBank"""
9     handle = Entrez.esearch(
10         db="nucleotide",
11         term=query,
12         retmax=max_results
13     )
14     record = Entrez.read(handle)
15     return record["IdList"]
16
17 # Download de sequencia
```

Análise de Features no GenBank

```
1 def extract_features(record):
2     """Extrai features de um registro GenBank"""
3     features_dict = {
4         'genes': [],
5         'CDS': [],
6         'mRNA': []
7     }
8
9     for feature in record.features:
10        if feature.type == 'gene':
11            gene_name = feature.qualifiers.get('gene', ['Unknown'])[0]
12            location = f"{feature.location.start}-{feature.location.end}"
13            features_dict['genes'].append({
14                'name': gene_name,
15                'location': location
```

Análise de Sequências: Pipeline Completo



Bancos de Dados Relacionados

NCBI

- **GenBank:** sequências
- **RefSeq:** curadas
- **GEO:** expressão
- **SRA:** sequenciamento
- **PubMed:** literatura

EBI (Europa)

- **ENA:** sequências
- **ArrayExpress:** microarrays
- **Ensembl:** genomas

Especializados

- **KEGG:** vias metabólicas
- **GO:** ontologia
- **UniProt:** proteínas
- **miRBase:** microRNAs
- **Rfam:** RNAs não-codificantes

Integração

Ferramentas como DAVID, Enrichr e WebGestalt integram múltiplos bancos

Ontologia Gênica (GO)

Definição: Gene Ontology

Vocabulário controlado para descrever funções de genes em três domínios:

- **MF:** Molecular Function (função molecular)
- **BP:** Biological Process (processo biológico)
- **CC:** Cellular Component (componente celular)

Exemplo: Hemoglobina

- **MF:** oxygen transporter activity (GO:0005344)
- **BP:** oxygen transport (GO:0015671)
- **CC:** hemoglobin complex (GO:0005833)

Análise de Enriquecimento

Caso 1: Análise de Expressão em Câncer

Objetivo

Identificar genes diferencialmente expressos entre tecido normal e tumoral

Abordagem:

1. Coletar dados de RNA-seq (GEO/TCGA)
2. Normalizar e filtrar
3. Análise de expressão diferencial (DESeq2)
4. Correção para múltiplos testes (FDR)
5. Análise de enriquecimento (GO, KEGG)
6. Validação experimental (qPCR)

Resultado Esperado

- Lista de genes super/sub-expressos
- Vias biológicas alteradas

Caso 2: Descoberta de microRNAs Regulatórios

Objetivo

Identificar miRNAs que regulam genes envolvidos em resposta ao estresse

Pipeline:

1. Perfil de expressão de miRNAs (small RNA-seq)
2. Perfil de expressão de mRNAs (RNA-seq)
3. Predição de alvos (TargetScan, miRanda)
4. Correlação inversa miRNA-mRNA
5. Validação experimental (luciferase assay)

Ferramentas

- **miRBase:** banco de miRNAs
- **TargetScan:** predição de alvos
- **DIANA TarBase:** interações validadas

Exercícios - Parte 1

Questão 1: Cálculo de Códon

Uma região codificante tem 1200 nucleotídeos.

1. Quantos códon ela contém?
2. Quantos aminoácidos na proteína resultante?
3. Se a taxa de tradução é 15 aa/segundo, quanto tempo leva?

Questão 2: Conteúdo GC

Por que o conteúdo GC é importante? Calcule o conteúdo GC da sequência:
5' -ATGCGATCGTAGCTAGCTA-3'

Questão 3: Função de Hill

Para uma função de Hill com $n = 4$, $K_d = 10$, $V_{max} = 100$:

1. Calcule a expressão quando $[TF] = 10$

Questão 4: Projeto Prático - Análise de Sequência

Escolha um gene de interesse (ex: TP53, BRCA1, MYC):

1. Baixe a sequência do GenBank usando BioPython
2. Identifique e anote todas as features
3. Calcule estatísticas básicas (tamanho, GC%, nº de éxons)
4. Identifique potenciais sítios de ligação de fatores de transcrição no promotor
5. Visualize a estrutura do gene (exons/introns)

Questão 5: RNA-seq

Com dados de contagens de RNA-seq:

1. Normalize os dados (TPM ou DESeq2)
2. Identifique genes diferencialmente expressos

Questão 6: Predição de miRNA

Dada uma sequência 3' UTR de um mRNA:

1. Use TargetScan para prever miRNAs que a regulam
2. Analise a conservação evolutiva dos sítios
3. Verifique dados de expressão: correlação negativa?
4. Proponha experimento para validar a interação

Projeto Final

Desenvolva um pipeline de análise completo:

1. Download de dados de RNA-seq do GEO
2. Controle de qualidade (FastQC)
3. Alinhamento ao genoma de referência

Referências Principais

-  Watson J.D. et al. (2013). *Molecular Biology of the Gene*, 7th ed. Pearson.
-  Alberts B. et al. (2022). *Molecular Biology of the Cell*, 7th ed. Garland Science.
-  Cock P.J.A. et al. (2009). Biopython: freely available Python tools for computational molecular biology and bioinformatics. *Bioinformatics*.
-  Love M.I. et al. (2014). Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biology*.
-  Bartel D.P. (2018). Metazoan MicroRNAs. *Cell*.

Livros

- Lewin B. (2020). *Genes XII*. Jones & Bartlett.
- Lodish H. et al. (2021). *Molecular Cell Biology*, 9th ed.
- Mount D.W. (2004). *Bioinformatics: Sequence and Genome Analysis*.

Recursos Online

- **NCBI Education:** <https://www.ncbi.nlm.nih.gov/guide/>
- **Ensembl:** <https://www.ensembl.org>
- **UCSC Genome Browser:** <https://genome.ucsc.edu>
- **GTEx Portal:** <https://gtexportal.org>
- **BioPython Tutorial:**
<http://biopython.org/DIST/docs/tutorial/Tutorial.html>

Obrigado!

Capítulo 6: Sistemas Gênicos

Próximo Capítulo:
Protein Systems (Sistemas Proteicos)

Dúvidas? Perguntas?