

# Capítulo 13: Systems Biology in Medicine

## Bioinformática para Biologia de Sistemas

Ney Lemke

DBF-Unesp

23 de maio de 2026

# Sumário

# Visão Geral do Capítulo

## Objetivos de Aprendizagem

- Compreender medicina de sistemas e medicina personalizada
- Aplicar biologia de sistemas à descoberta de fármacos
- Modelar doenças complexas como sistemas integrados
- Explorar farmacogenômica e estratificação de pacientes
- Analisar estudos de caso clínicos com abordagens sistêmicas


## Por que Systems Medicine?

- Doenças complexas requerem abordagens integrativas
- Medicina personalizada baseada em perfis moleculares
- Descoberta de fármacos mais eficiente e segura
- Previsão de respostas terapêuticas individualizadas

# Da Bancada ao Leito: Medicina de Sistemas

## Definição: Medicina de Sistemas

Aplicação dos princípios da biologia de sistemas à medicina clínica, integrando dados multi-ômicos, redes moleculares e modelagem computacional para compreender, diagnosticar e tratar doenças.



# Medicina Personalizada e de Precisão

## Medicina Tradicional

- Abordagem "one-size-fits-all"
- Tratamento baseado em sintomas
- Decisões empíricas
- Resposta variável

## Medicina Personalizada

- Tratamento individualizado
- Baseada em perfil molecular
- Decisões orientadas por dados
- Resposta otimizada

## Importante!

Medicina personalizada = tratamento certo + paciente certo + momento certo

## Pilares da Medicina de Precisão

- Genômica individual
- Biomarcadores moleculares

# Abordagens Sistêmicas para Doenças

## Mudança de Paradigma

| Aspecto | Tradicional         | Sistêmica         |
|---------|---------------------|-------------------|
| Foco    | Gene/proteína única | Redes moleculares |
| Causa   | Linear              | Multifatorial     |
| Terapia | Alvo único          | Multi-alvo        |
| Dados   | Isolados            | Integrados        |
| Modelo  | Reduccionista       | Holístico         |

## Aplicações Clínicas

- Identificação de alvos terapêuticos
- Reposicionamento de fármacos
- Biomarcadores diagnósticos e prognósticos

# Descoberta de Fármacos: Tradicional vs Sistêmica

## Abordagem Tradicional:

1. Identificar alvo único
2. Triagem de compostos
3. Otimização de lead
4. Testes pré-clínicos
5. Ensaios clínicos

## Limitações:

- Alta taxa de falha (>90%)
- Custo elevado (\$2.6 bilhões)
- Tempo longo (10-15 anos)
- Efeitos adversos inesperados

## Abordagem Sistêmica:

1. Análise de redes
2. Identificação de módulos
3. Alvos múltiplos/sinérgicos
4. Modelagem *in silico*
5. Estratificação de pacientes

## Vantagens:

- Melhor compreensão de mecanismos
- Previsão de efeitos adversos
- Reposicionamento de fármacos
- Medicina personalizada

# Identificação e Validação de Alvos

## Pipeline Sistêmico

### 1. Análise de redes de doenças

- Identificar genes/proteínas associados à doença
- Análise de centralidade (degree, betweenness, closeness)
- Identificar hubs e bottlenecks

### 2. Módulos de doença

- Detecção de comunidades
- Módulos funcionalmente relacionados
- Proximidade de rede


### 3. Critérios de validação

- Druggability (capacidade de ser alvo de fármaco)
- Especificidade tecidual
- Papel funcional validado
- Sem efeitos adversos graves

# Farmacologia de Redes (Network Pharmacology)

## Definição: Network Pharmacology

Estudo de interações fármaco-alvo no contexto de redes biológicas, reconhecendo que fármacos afetam múltiplos alvos e vias.



**Importante!**

Polifarmacologia: um fármaco, múltiplos alvos → efeitos sinérgicos

# Fármacos Multi-Alvo

## Conceito

Fármacos projetados para modular múltiplos alvos simultaneamente, explorando sinergias e redundâncias em redes biológicas.

## Vantagens:

- Maior eficácia
- Menor resistência
- Efeitos sinérgicos
- Adequado para doenças complexas

## Exemplos:

- Inibidores multi-quinase (câncer)
- Aspirina (COX-1/COX-2)

## Desafios:

- Design complexo
- Otimização de múltiplos alvos
- Previsão de efeitos adversos
- Propriedades farmacocinéticas

## Índice de Seletividade

$$S = \frac{IC_{50}(\text{off-target})}{IC_{50}(\text{on-target})}$$

# Redes de Interação Fármaco-Alvo

## Construção de Redes DTI

### Dados:

- Estrutura química de fármacos
- Estrutura 3D de proteínas alvo
- Dados de afinidade ( $IC_{50}$ ,  $K_d$ )
- Screening em larga escala
- Bases de dados: DrugBank, ChEMBL, BindingDB

### Análises:

- Grau de promiscuidade de fármacos
- Polifarmacologia

### Métrica de Promiscuidade

$$P_d = \frac{\# \text{ alvos do fármaco}}{\# \text{ total de fármacos}}$$

Fármacos com  $P_d$  alto:

## ADME

- **Absorção:** entrada do fármaco no organismo
- **Distribuição:** dispersão pelos tecidos
- **Metabolismo:** biotransformação (fígado)
- **Excreção:** eliminação (rins, bile)

## Fatores que afetam ADME:

- Propriedades físico-químicas
- Solubilidade, permeabilidade
- Ligação a proteínas plasmáticas
- Metabolismo de primeira passagem
- Polimorfismos genéticos (CYP450)

## Regra de Lipinski (Regra dos 5)

Fármaco oralmente biodisponível:

- Peso molecular  $< 500$  Da
- $\text{LogP} < 5$
- Doadores H-bond  $\leq 5$
- Aceptores H-bond  $\leq 10$

# Modelagem PK/PD

## Definição: Farmacocinética/Farmacodinâmica

**PK:** "O que o corpo faz com o fármaco— concentração vs tempo

**PD:** "O que o fármaco faz com o corpo— efeito vs concentração

## Modelos Compartimentais


Representam o corpo como compartimentos onde o fármaco se distribui.

### Tipos:

- Modelo de 1 compartimento (mais simples)
- Modelo de 2 compartimentos (central + periférico)
- Modelo de 3+ compartimentos (tecidos específicos)

## Parâmetros PK Importantes

# Modelo de Um Compartimento



EDO:

$$\frac{dC}{dt} = -k_e C$$

Solução (dose IV):

$$C(t) = C_0 e^{-k_e t}$$


Parâmetros:

$$t_{1/2} = \frac{\ln 2}{k_e} = \frac{0.693}{k_e}$$

$$CL = k_e \cdot V_d$$

$$AUC = \frac{C_0}{k_e} = \frac{\text{Dose}}{CL}$$

# Modelo de Dois Compartimentos



Sistema de EDOs:

$$\begin{aligned}\frac{dC_1}{dt} &= -(k_e + k_{12})C_1 + k_{21}C_2 \\ \frac{dC_2}{dt} &= k_{12}C_1 - k_{21}C_2\end{aligned}$$

# Simulação PK: Modelo de Um Compartimento

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.integrate import odeint
4
5 def one_compartment_pk(C, t, ke):
6     """Modelo PK de 1 compartimento"""
7     dCdt = -ke * C
8     return dCdt
9
10 # Parametros
11 ke = 0.2          # constante de eliminacao (1/h)
12 C0 = 100          # concentracao inicial (mg/L)
13 t_half = 0.693 / ke # meia-vida
14
15 # Tempo
16 t = np.linspace(0, 24, 200)
17
```

# Ensaio Clínicos e Biologia de Sistemas

## Fases de Ensaio Clínicos

- **Fase I:** Segurança, farmacocinética (20-100 voluntários)
- **Fase II:** Eficácia preliminar, dose (100-500 pacientes)
- **Fase III:** Eficácia, efeitos adversos (1000-5000 pacientes)
- **Fase IV:** Monitoramento pós-comercialização

## Aplicações de Biologia de Sistemas

- **Design de ensaios:** Estratificação de pacientes por perfil molecular
- **Biomarcadores:** Identificação de marcadores de resposta/toxicidade
- **Ensaio *in silico*:** "Digital twins" para prever resultados
- **Adaptive trials:** Ajustes baseados em dados intermediários
- **Análise de subgrupos:** Identificar respondedores vs não-respondedores

# Câncer como Doença Sistêmica

## Definição: Visão Sistêmica do Câncer

Câncer não é apenas uma doença de um gene mutado, mas resulta de alterações em redes regulatórias, vias de sinalização e interações com o microambiente tumoral.

### Características:

- Heterogeneidade genômica
- Plasticidade celular
- Evolução clonal
- Interações com estroma
- Resposta imune
- Metabolismo reprogramado

### Níveis de Complexidade:

- Genético: mutações driver/passenger
- Epigenético: metilação, histonas
- Transcriptômico: expressão gênica
- Proteômico: sinalização
- Metabólico: Warburg, glutaminólise
- Microambiente: células imunes, CAFs

**Importante!**

# Hallmarks of Cancer

## 10 Características Essenciais do Câncer (Hanahan & Weinberg)

### Características Principais:

1. Sinais de crescimento sustentado
2. Evasão de supressores de crescimento
3. Resistência à morte celular
4. Imortalidade replicativa
5. Angiogênese induzida
6. Invasão e metástase

### Características Emergentes:

7. Reprogramação metabólica
8. Evasão imune


### Características Facilitadoras:

9. Instabilidade genômica
10. Inflamação promotora de tumor

## Implicações Terapêuticas

Cada hallmark representa um alvo terapêutico potencial

# Redes Oncogênicas e Supressoras de Tumor



Oncogenes at-  
vam proliferação  
Supressores ini-  
bem proliferação

Importante!

# Metabolismo do Câncer: Efeito Warburg

## Definição: Efeito Warburg

Células cancerosas preferem glicólise aeróbica (menos eficiente) em vez de fosforilação oxidativa, mesmo na presença de oxigênio.

## Vantagens para tumor:

- Geração rápida de ATP
- Biomassa (nucleotídeos, lipídios)
- Acidificação do microambiente
- Evasão de apoptose mitocondrial

## Reprogramação Metabólica

### Vias alteradas:

- ↑ Captação de glicose (GLUT1)
- ↑ Glicólise (HK2, PKM2)
- ↑ Glutaminólise
- ↑ Síntese de lipídios (FASN)
- ↓ OXPHOS


## Alvos Metabólicos

- Inibidores de hexoquinase
- Inibidores de LDH-A
- Inibidores de glutaminase

# Heterogeneidade Tumoral

## Tipos de Heterogeneidade

- **Intratumoral:** diferentes clones no mesmo tumor
- **Intertumoral:** variação entre pacientes
- **Temporal:** evolução durante tratamento
- **Espacial:** gradientes no microambiente



# Doenças Cardiovasculares como Sistemas

## Redes em Doenças Cardiovasculares

Doenças cardiovasculares envolvem interações complexas entre:

- Fatores genéticos (polimorfismos, mutações)
- Metabolismo lipídico (colesterol, triglicerídeos)
- Inflamação (citocinas, células imunes)
- Função endotelial (NO, vasodilatação)
- Coagulação (plaquetas, fatores de coagulação)
- Pressão arterial (RAAS, SNS)

### Aterosclerose:

- Acúmulo de LDL oxidado
- Recrutamento de macrófagos

### Abordagens Sistêmicas:

- Identificação de módulos de risco
- Biomarcadores multi-ômicos

# Diabetes e Síndrome Metabólica

## Diabetes Tipo 2: Doença Sistêmica

### Componentes interconectados:

- Resistência à insulina (músculo, fígado, tecido adiposo)
- Disfunção de células  $\beta$  pancreáticas
- Metabolismo de glicose alterado
- Lipotoxicidade
- Inflamação crônica de baixo grau
- Estresse oxidativo

### Síndrome Metabólica:

1. Obesidade abdominal
2. Hiperglicemia

### Modelagem Sistêmica

- Modelos de homeostase glicose-insulina
- Redes de sinalização insulínica

# Doenças Neurodegenerativas

## Alzheimer

### Características:

- Placas amiloides ( $\beta$ -amiloide)
- Emaranhados neurofibrilares (tau)
- Neuroinflamação
- Perda sináptica
- Disfunção mitocondrial
- Estresse oxidativo

### Fatores de risco:

- APOE4 (genético)
- Idade

## Parkinson

### Características:

- Perda de neurônios dopaminérgicos
- Corps de Lewy ( $\alpha$ -sinucleína)
- Disfunção mitocondrial
- Estresse do RE
- Neuroinflamação


### Genes associados:

- SNCA, LRRK2, PARK7
- GBA, PINK1, PARKIN

# Módulos de Doença (Disease Modules)

## Definição: Módulo de Doença

Conjunto de genes/proteínas topologicamente próximos no interactoma humano cujas perturbações estão associadas a um fenótipo patológico comum.



# Classificação de Doenças Baseada em Redes

## Abordagem Tradicional vs Sistêmica

| Critério       | Tradicional       | Baseada em Rede     |
|----------------|-------------------|---------------------|
| Base           | Sintomas clínicos | Módulos moleculares |
| Foco           | Órgão/tecido      | Vias e redes        |
| Resolução      | Baixa             | Alta (molecular)    |
| Personalização | Limitada          | Alta                |
| Preditiva      | Moderada          | Alta                |

## Exemplos

- **Câncer:** Classificação por perfil de expressão e mutações (The Cancer Genome Atlas - TCGA)
- **Diabetes:** Subtipos baseados em resistência à insulina vs disfunção de células  $\beta$

# Farmacogenômica

## Definição: Farmacogenômica

Estudo de como variações genéticas individuais influenciam a resposta a fármacos, incluindo eficácia e toxicidade.

## Fontes de Variabilidade na Resposta a Fármacos

- **Farmacocinética:** variantes em genes ADME (CYP450, transportadores)
- **Farmacodinâmica:** variantes em alvos terapêuticos (receptores, enzimas)
- **Doença:** heterogeneidade molecular da doença
- **Ambiente:** dieta, comorbidades, interações medicamentosas

## Objetivos:

- Maximizar eficácia

## Benefícios

- Medicina personalizada

# Polimorfismos do Citocromo P450

## Família CYP450

Enzimas hepáticas responsáveis pelo metabolismo de 75% dos fármacos

### Principais isoformas:

- **CYP2D6:** 25% dos fármacos (antidepressivos, opioides, betabloqueadores)
- **CYP2C9:** warfarina, NSAIDs, hipoglicemiantes
- **CYP2C19:** clopidogrel, IBPs, antidepressivos
- **CYP3A4/5:** 50% dos fármacos (estatinas, imunossupressores)

## Fenótipos Metabólicos

| Fenótipo              | Atividade   | Implicação                                     |
|-----------------------|-------------|------------------------------------------------|
| Poor Metabolizer (PM) | Muito baixa | ↑ toxicidade, ↑ dose necessária (pró-fármacos) |
| Intermediate (IM)     | Reduzida    | Monitoramento                                  |

# Exemplo: Clopidogrel e CYP2C19

## Clopidogrel:


- Pró-fármaco antiagregante
- Previne trombose (pós-stent)
- Requer ativação por CYP2C19

## Polimorfismo CYP2C19:

- \*1/\*1 (EM): metabolizador normal
- \*2, \*3 (PM): perda de função
- \*17 (UM): ganho de função

### Importante!

PM têm ↑3x risco de eventos cardiovasculares



## Recomendação Clínica:

- PM: usar prasugrel ou ticagrelor (alternativas)
- EM: clopidogrel dose padrão
- UM: monitorar cuidadosamente

# Descoberta de Biomarcadores

## Tipos de Biomarcadores

- **Diagnóstico:** detectar presença de doença
- **Prognóstico:** prever evolução da doença
- **Preditivo:** prever resposta a terapia
- **Farmacodinâmico:** medir efeito do tratamento
- **Segurança:** detectar toxicidade

## Pipeline de Descoberta

1. **Discovery:** análise ômica em larga escala (casos vs controles)
2. **Verificação:** validação em coorte independente
3. **Qualificação:** ensaios prospectivos
4. **Implementação:** testes clínicos validados

# Estratificação de Pacientes

## Conceito

Classificar pacientes em subgrupos com base em características moleculares, clínicas ou demográficas para tratamento personalizado.

## Métodos:

- Clustering (K-means, hierárquico)
- Análise de componentes principais (PCA)
- Non-negative matrix factorization (NMF)
- Machine learning supervisionado
- Network-based stratification

## Aplicações

- **Ensaio clínico:** enriquecer para respondedores
- **Diagnóstico:** classificar subtipos
- **Prognóstico:** identificar alto vs baixo risco
- **Terapia:** selecionar tratamento ótimo

# Diagnósticos Baseados em Ômicas

## Testes Multi-Ômicos Clínicos

### Genômicos:

- Sequenciamento de painel de genes (câncer)
- Whole-exome sequencing (WES)
- Whole-genome sequencing (WGS)
- Liquid biopsy (ctDNA)

### Transcriptômicos:

- Oncotype DX (câncer de mama)
- MammaPrint (prognóstico de mama)
- Prosigna (PAM50)

### Proteômicos/Metabólicos:

- Painéis de citocinas

# Subtipos de Câncer de Mama

## Classificação Molecular (PAM50)


Baseada em perfil de expressão de 50 genes:

| Subtipo    | Marcadores                    | Prognóstico   | Tratamento           |
|------------|-------------------------------|---------------|----------------------|
| Luminal A  | ER+, PR+, HER2-, Ki67 baixo   | Melhor        | Hormonioterapia      |
| Luminal B  | ER+, HER2+/- , Ki67 alto      | Intermediário | Hormônio + quimio    |
| HER2+      | ER-, PR-, HER2+               | Intermediário | Trastuzumab + quimio |
| Basal-like | ER-, PR-, HER2- (triplo neg.) | Pior          | Quimioterapia        |

## Importante!

Mesmo órgão, histologia similar → diferentes doenças moleculares → tratamentos distintos

# Seleção de Tratamento por Perfil Molecular



## Exemplos Clínicos

- **EGFR mutado:** erlotinib/gefitinib (câncer de pulmão)
- **BRAF V600E:** vemurafenib (melanoma)
- **ALK fusão:** crizotinib (câncer de pulmão)
- **BCR-ABL:** imatinib (leucemia mieloide crônica)

# Digital Twins e Ensaios Clínicos *In Silico*

## Definição: Digital Twin

Réplica computacional personalizada de um paciente individual, baseada em dados multi-ômicos, clínicos e fisiológicos, que permite simular respostas a intervenções terapêuticas.

## Componentes:

- Dados do paciente (genoma, transcriptoma, metaboloma, clínicos)
- Modelos mecanísticos (redes, EDOs)
- Parâmetros personalizados
- Simulação computacional

## Ensaios *In Silico*

- Testar milhares de cenários rapidamente
- Reduzir necessidade de ensaios animais
- Acelerar desenvolvimento de fármacos
- Stratificação pré-clínica

# Desafios em Medicina Personalizada

## Desafios Técnicos

- **Integração de dados:** multi-ômicos heterogêneos
- **Interpretação:** variantes de significado incerto (VUS)
- **Validação:** necessidade de estudos prospectivos
- **Padronização:** protocolos laboratoriais e análise
- **Custo:** sequenciamento e análise ainda caros

## Desafios Éticos e Sociais

- **Privacidade:** dados genômicos sensíveis
- **Consentimento:** uso de dados, achados incidentais
- **Equidade:** acesso desigual a tecnologias
- **Discriminação:** genética por seguradoras/empregadores


# Estudo de Caso: Câncer de Mama HER2+ e Trastuzumab

## Contexto Clínico

- 15-20% dos cânceres de mama superexpressam HER2
- HER2 (ERBB2): receptor tirosina-quinase
- Superexpressão → proliferação descontrolada
- Prognóstico pior (antes de terapias-alvo)

## Trastuzumab (Herceptin):

- Anticorpo monoclonal anti-HER2
- Bloqueia sinalização HER2
- Induz resposta imune (ADCC)
- Primeiro sucesso de medicina personalizada em oncologia



# Doenças Infecciosas: Abordagem Sistêmica

## Interações Hospedeiro-Patógeno

Visão sistêmica considera:

- Redes moleculares do patógeno
- Resposta imune do hospedeiro
- Interações proteína-proteína (patógeno-hospedeiro)
- Modulação de vias do hospedeiro por patógeno
- Evolução e adaptação do patógeno

## Aplicações:

- Identificação de alvos terapêuticos (essenciais para patógeno)
- Reposicionamento de fármacos

## Exemplo: Tuberculose

- Rede metabólica de *M. tuberculosis*
- Identificar enzimas essenciais
- Testar *in silico* inibidores

# Resistência a Antibióticos como Problema Sistêmico

## Mecanismos de Resistência

- Mutações em alvos (RNA polimerase, ribossomo)
- Bombas de efluxo (superexpressão)
- Enzimas inativadoras ( $\beta$ -lactamases)
- Modificação de alvos (metilação de RNA ribossomal)
- Biofilmes (tolerância)

## Abordagens Sistêmicas:

- Análise de redes de resistência
- Identificar vulnerabilidades colaterais
- Terapias combinadas racionais

## Estratégias

- **Collateral sensitivity:** resistência a A causa sensibilidade a B
- **Terapias alternadas:** reduzir pressão seletiva

## Imunoterapia do Câncer

Estratégias que ativam o sistema imune para eliminar células tumorais:

- **Checkpoint inhibitors:** anti-PD-1, anti-CTLA-4 (bloqueiam sinais inibitórios)
- **CAR-T cells:** células T geneticamente modificadas
- **Vacinas terapêuticas:** antígenos tumorais
- **Oncolytic viruses:** vírus que infectam e lisam tumor

## Desafios:

- Apenas 20-40% respondem
- Efeitos adversos (autoimunidade)
- Microambiente imunossupressor


## Imunologia de Sistemas:

- Perfil de infiltrado imune (hot vs cold tumors)
- Assinaturas de resposta
- Carga mutacional tumoral (TMB)

# Terapia com Células CAR-T

## Conceito

Células T do paciente são geneticamente modificadas para expressar receptor de antígeno quimérico (CAR) que reconhece antígeno tumoral específico.



## Modelagem Sistêmica:

### Sucessos:

- Leucemias/linfomas B (CD19)
- Dinâmica CAR-T vs tumor
- Predição de síndrome de liberação de

# Design de Vacinas: Abordagem Sistêmica

## Vacinologia de Sistemas

Uso de abordagens ômicas e modelagem para:

- Identificar antígenos imunogênicos e protetores
- Prever resposta imune a candidatos vacinais
- Otimizar formulações e adjuvantes
- Estratificar respondedores vs não-respondedores
- Compreender correlatos de proteção

### Pipeline:

1. Genômica de patógeno
2. Predição de epítomos (MHC binding)

### Exemplo: Vacinas mRNA (COVID-19)

- Análise genômica rápida do SARS-CoV-2

# COVID-19 e Resposta de Biologia de Sistemas

## Contribuições de Systems Biology na Pandemia

- **Genômica viral:** sequenciamento rápido, rastreamento de variantes
- **Reposicionamento de fármacos:** análise de redes identificou candidatos (remdesivir, dexametasona)
- **Resposta imune:** perfis de citocinas, assinaturas de gravidade (tempestade de citocinas)
- **Interações proteína-proteína:** mapa de interações SARS-CoV-2-humano
- **Modelagem epidemiológica:** previsão de disseminação, impacto de intervenções
- **Vacinas:** design racional (mRNA, vetores virais)

## Biomarcadores de Gravidade

- IL-6, D-dímero, ferritina ↑ em casos graves

# Exemplo: Estratificação de Pacientes com Clustering

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from sklearn.cluster import KMeans
4 from sklearn.preprocessing import StandardScaler
5 from sklearn.decomposition import PCA
6
7 # Dados simulados: pacientes x features (omicas + clinicas)
8 np.random.seed(42)
9 n_patients = 100
10 data = np.random.randn(n_patients, 10) # 10 features
11
12 # Normalizar
13 scaler = StandardScaler()
14 data_scaled = scaler.fit_transform(data)
15
16 # Clustering K-means
17 kmeans = KMeans(n_clusters=3, random_state=42)
```

# Exercícios - Parte 1: Farmacocinética

## Questão 1: Modelo PK

Um paciente recebe dose IV bolus de 500 mg de um fármaco. O volume de distribuição é  $V_d = 50$  L e a meia-vida é  $t_{1/2} = 4$  h.

1. Calcule a constante de eliminação  $k_e$
2. Calcule o clearance (CL)
3. Qual será a concentração após 8 horas?
4. Calcule a AUC (área sob a curva)

## Questão 2: Modelo de Dois Compartimentos

Implemente um modelo farmacocinético de dois compartimentos em Python e simule a concentração ao longo de 24 horas. Use os seguintes parâmetros:

- $k_e = 0.15 \text{ h}^{-1}$ ,  $k_{12} = 0.3 \text{ h}^{-1}$ ,  $k_{21} = 0.2 \text{ h}^{-1}$
- Dose = 1000 mg IV,  $C(0) = 20 \text{ mg/L}$ ,  $C(0) = 0$

# Exercícios - Parte 2: Redes de Doenças

## Questão 3: Análise de Rede DTI

Dado o seguinte grafo bipartido de interações fármaco-alvo:

- Fármaco A: alvos T1, T2, T3
- Fármaco B: alvos T2, T4
- Fármaco C: alvos T3, T4, T5

1. Construa a matriz de adjacência
2. Calcule o grau de promiscuidade de cada fármaco
3. Identifique alvos compartilhados (potencial para efeitos adversos similares)
4. Sugira reposicionamento de fármacos baseado em sobreposição de alvos

## Questão 4: Módulos de Doença

Use algoritmo de Louvain ou Girvan-Newman para detectar módulos em uma rede de

# Exercícios - Parte 3: Medicina Personalizada

## Questão 5: Farmacogenômica

Um paciente é metabolizador pobre (PM) de CYP2D6 e recebe codeína (pró-fármaco convertido em morfina por CYP2D6).

1. Preveja o efeito no manejo da dor
2. Qual ajuste de dose ou medicação alternativa você recomendaria?
3. Como você explicaria ao paciente a importância do teste farmacogenômico?

## Questão 6: Estratificação de Pacientes

Implemente clustering K-means em um dataset de expressão gênica de câncer de mama (use dataset público como TCGA ou simulado). Identifique subgrupos moleculares e compare com subtipos clínicos conhecidos (Luminal A/B, HER2+, Basal).

# Projeto Prático: Análise de Dados Clínicos Ômicos

## Projeto Integrador

**Objetivo:** Analisar dados multi-ômicos de pacientes com câncer para identificar biomarcadores e estratificar pacientes.

### Etapas:

1. **Dados:** Baixar dados de expressão gênica e clínicos (TCGA, GEO, cBioPortal)
2. **Pré-processamento:** Normalização, controle de qualidade, filtro de variância
3. **Análise exploratória:** PCA, heatmaps, clustering hierárquico
4. **Clustering:** K-means ou NMF para identificar subgrupos
5. **Biomarcadores:** Análise diferencial (DESeq2, limma) entre subgrupos
6. **Sobrevida:** Curvas de Kaplan-Meier, teste log-rank
7. **Validação:** Dataset independente
8. **Interpretação biológica:** Enriquecimento funcional (GO, KEGG)

# Referências Principais

-  Barabási A.L., Gulbahce N., Loscalzo J. (2011). *Network medicine: a network-based approach to human disease*. Nature Reviews Genetics 12:56-68.
-  Auffray C., Chen Z., Hood L. (2009). *Systems medicine: the future of medical genomics and healthcare*. Genome Medicine 1:2.
-  Schadt E.E. (2009). *Molecular networks as sensors and drivers of common human diseases*. Nature 461:218-223.
-  Zhou X., Menche J., Barabási A.L., Sharma A. (2014). *Human symptoms-disease network*. Nature Communications 5:4212.
-  Hanahan D., Weinberg R.A. (2011). *Hallmarks of cancer: the next generation*. Cell 144:646-674.

# Referências: Network Medicine e Farmacologia

-  Hopkins A.L. (2008). *Network pharmacology: the next paradigm in drug discovery*. Nature Chemical Biology 4:682-690.
-  Zhao S., Iyengar R. (2012). *Systems pharmacology: network analysis to identify multiscale mechanisms of drug action*. Annual Review of Pharmacology and Toxicology 52:505-521.
-  Csermely P., Korcsmáros T., Kiss H.J., et al. (2013). *Structure and dynamics of molecular networks: a novel paradigm of drug discovery*. Pharmacology & Therapeutics 138:333-408.
-  Menche J., Sharma A., Kitsak M., et al. (2015). *Disease networks: uncovering disease-disease relationships through the incomplete interactome*. Science 347:1257601.

# Referências: Medicina Personalizada e Ômicas

-  Ashley E.A. (2016). *Towards precision medicine*. Nature Reviews Genetics 17:507-522.
-  Roden D.M., McLeod H.L., Relling M.V., et al. (2019). *Pharmacogenomics*. The Lancet 394:521-532.
-  Chen R., Snyder M. (2013). *Promise of personalized omics to precision medicine*. Wiley Interdisciplinary Reviews: Systems Biology and Medicine 5:73-82.
-  Brunet J.P., et al. (2004). *Metagenes and molecular pattern discovery using matrix factorization*. PNAS 101:4164-4169.

## Bases de Dados Clínicas e Farmacogenômicas

- **DrugBank:** <https://go.drugbank.com> — fármacos, alvos, PK/PD
- **TCGA:** <https://portal.gdc.cancer.gov> — dados multi-ômicos de câncer
- **UK Biobank:** <https://www.ukbiobank.ac.uk> — dados de saúde populacional
- **ClinVar:** <https://www.ncbi.nlm.nih.gov/clinvar> — variantes clínicas
- **PharmGKB:** <https://www.pharmgkb.org> — farmacogenômica

## Ferramentas de Análise

- **cBioPortal:** <https://www.cbioportal.org> — análise de dados de câncer
- **STRING:** <https://string-db.org> — interações proteína-proteína
- **Cytoscape:** <https://cytoscape.org> — visualização de redes
- **GSEA:** <https://www.gsea-msigdb.org> — enriquecimento funcional

## Livros e Reviews

- Loscalzo J., Barabási A.L., Silverman E.K. (2017). *Network Medicine: Complex Systems in Human Disease and Therapeutics*. Harvard University Press.
- Zhu H., Xia M. (2016). *Advances in Systems Biology*. Springer.
- Wolkenhauer O. (2013). *Systems Medicine*. Springer.

## Artigos de Revisão Importantes

- Hood L., Friend S.H. (2011). *Predictive, personalized, preventive, participatory (P4) cancer medicine*. Nature Reviews Clinical Oncology 8:184-187.
- Ideker T., Krogan N.J. (2012). *Differential network biology*. Molecular Systems Biology 8:565.
- Califano A., Alvarez M.J. (2017). *The recurrent architecture of tumour initiation, progression and drug sensitivity*. Nature Reviews Cancer 17:116-130.

# Obrigado!

## Capítulo 13: Systems Biology in Medicine

### **Tópicos Abordados:**

Descoberta de fármacos · Doenças complexas  
Medicina personalizada · Aplicações clínicas

*Dúvidas? Perguntas?*

*A medicina do futuro é sistêmica, preditiva, personalizada e participativa*