

Capítulo 13: Systems Biology in Medicine

Bioinformática para Biologia de Sistemas

Ney Lemke

DBF-Unesp

23 de junho de 2026

Sumário

- 1 Introdução
- 2 Descoberta e Desenvolvimento de Fármacos
- 3 Doenças Complexas
- 4 Medicina Personalizada
- 5 Aplicações Clínicas
- 6 Exercícios
- 7 Referências

Visão Geral do Capítulo

Objetivos de Aprendizagem

- Compreender medicina de sistemas e medicina personalizada
- Aplicar biologia de sistemas à descoberta de fármacos
- Modelar doenças complexas como sistemas integrados
- Explorar farmacogenômica e estratificação de pacientes
- Analisar estudos de caso clínicos com abordagens sistêmicas


Por que Systems Medicine?

- Doenças complexas requerem abordagens integrativas
- Medicina personalizada baseada em perfis moleculares
- Descoberta de fármacos mais eficiente e segura
- Previsão de respostas terapêuticas individualizadas

Da Bancada ao Leito: Medicina de Sistemas

Definição: Medicina de Sistemas

Aplicação dos princípios da biologia de sistemas à medicina clínica, integrando dados multi-ômicos, redes moleculares e modelagem computacional para compreender, diagnosticar e tratar doenças.



Medicina Personalizada e de Precisão

Medicina Tradicional

- Abordagem "one-size-fits-all"
- Tratamento baseado em sintomas
- Decisões empíricas
- Resposta variável

Medicina Personalizada

- Tratamento individualizado
- Baseada em perfil molecular
- Decisões orientadas por dados
- Resposta otimizada

Importante!

Medicina personalizada = tratamento certo + paciente certo + momento certo

Pilares da Medicina de Precisão

- Genômica individual
- Biomarcadores moleculares
- Estratificação de pacientes
- Farmacogenômica

Abordagens Sistêmicas para Doenças

Mudança de Paradigma

Aspecto	Tradicional	Sistêmica
Foco	Gene/proteína única	Redes moleculares
Causa	Linear	Multifatorial
Terapia	Alvo único	Multi-alvo
Dados	Isolados	Integrados
Modelo	Reduccionista	Holístico

Aplicações Clínicas

- Identificação de alvos terapêuticos
- Reposicionamento de fármacos
- Biomarcadores diagnósticos e prognósticos
- Estratificação de pacientes em ensaios clínicos
- Previsão de efeitos adversos

Descoberta de Fármacos: Tradicional vs Sistêmica

Abordagem Tradicional:

1. Identificar alvo único
2. Triagem de compostos
3. Otimização de lead
4. Testes pré-clínicos
5. Ensaios clínicos

Limitações:

- Alta taxa de falha (>90%)
- Custo elevado (\$2.6 bilhões)
- Tempo longo (10-15 anos)
- Efeitos adversos inesperados

Abordagem Sistêmica:

1. Análise de redes
2. Identificação de módulos
3. Alvos múltiplos/sinérgicos
4. Modelagem *in silico*
5. Estratificação de pacientes

Vantagens:

- Melhor compreensão de mecanismos
- Previsão de efeitos adversos
- Reposicionamento de fármacos
- Medicina personalizada

Pipeline Sistêmico

1. Análise de redes de doenças

- Identificar genes/proteínas associados à doença
- Análise de centralidade (degree, betweenness, closeness)
- Identificar hubs e bottlenecks

2. Módulos de doença

- Detecção de comunidades
- Módulos funcionalmente relacionados
- Proximidade de rede


3. Critérios de validação

- Druggability (capacidade de ser alvo de fármaco)
- Especificidade tecidual
- Papel funcional validado
- Sem efeitos adversos graves

Farmacologia de Redes (Network Pharmacology)

Definição: Network Pharmacology

Estudo de interações fármaco-alvo no contexto de redes biológicas, reconhecendo que fármacos afetam múltiplos alvos e vias.



Importante!

Polifarmacologia: um fármaco, múltiplos alvos → efeitos sinérgicos

Fármacos Multi-Alvo

Conceito

Fármacos projetados para modular múltiplos alvos simultaneamente, explorando sinergias e redundâncias em redes biológicas.

Vantagens:

- Maior eficácia
- Menor resistência
- Efeitos sinérgicos
- Adequado para doenças complexas

Exemplos:

- Inibidores multi-quinase (câncer)
- Aspirina (COX-1/COX-2)
- Estatinas (HMG-CoA + pleiotrópicos)

Desafios:

- Design complexo
- Otimização de múltiplos alvos
- Previsão de efeitos adversos
- Propriedades farmacocinéticas

Índice de Seletividade

$$S = \frac{IC_{50}(\text{off-target})}{IC_{50}(\text{on-target})}$$

$S > 100$: seletivo

$S < 10$: multi-alvo

Redes de Interação Fármaco-Alvo

Construção de Redes DTI

Dados:

- Estrutura química de fármacos
- Estrutura 3D de proteínas alvo
- Dados de afinidade (IC_{50} , K_d)
- Screening em larga escala
- Bases de dados: DrugBank, ChEMBL, BindingDB

Análises:

- Grau de promiscuidade de fármacos
- Polifarmacologia
- Reposicionamento
- Previsão de efeitos adversos

Métrica de Promiscuidade

$$P_d = \frac{\# \text{ alvos do fármaco}}{\# \text{ total de fármacos}}$$

Fármacos com P_d alto:

- Maior chance de efeitos adversos
- Potencial para reposicionamento

ADME

- **Absorção:** entrada do fármaco no organismo
- **Distribuição:** dispersão pelos tecidos
- **Metabolismo:** biotransformação (fígado)
- **Excreção:** eliminação (rins, bile)

Fatores que afetam ADME:

- Propriedades físico-químicas
- Solubilidade, permeabilidade
- Ligação a proteínas plasmáticas
- Metabolismo de primeira passagem
- Polimorfismos genéticos (CYP450)

Regra de Lipinski (Regra dos 5)

Fármaco oralmente biodisponível:

- Peso molecular < 500 Da
- $\text{LogP} < 5$
- Doadores H-bond ≤ 5
- Aceptores H-bond ≤ 10

Modelagem PK/PD

Definição: Farmacocinética/Farmacodinâmica

PK: "O que o corpo faz com o fármaco— concentração vs tempo

PD: "O que o fármaco faz com o corpo— efeito vs concentração

Modelos Compartimentais

Representam o corpo como compartimentos onde o fármaco se distribui.


Tipos:

- Modelo de 1 compartimento (mais simples)
- Modelo de 2 compartimentos (central + periférico)
- Modelo de 3+ compartimentos (tecidos específicos)

Parâmetros PK Importantes

- C_{max} : concentração máxima
- T_{max} : tempo de concentração máxima
- AUC: área sob a curva (exposição total)
- $t_{1/2}$: meia-vida de eliminação
- V_d : volume de distribuição
- CL: clearance (depuração)

Modelo de Um Compartimento



EDO:

$$\frac{dC}{dt} = -k_e C$$

Solução (dose IV):

$$C(t) = C_0 e^{-k_e t}$$


Parâmetros:

$$t_{1/2} = \frac{\ln 2}{k_e} = \frac{0.693}{k_e}$$

$$CL = k_e \cdot V_d$$

$$AUC = \frac{C_0}{k_e} = \frac{\text{Dose}}{CL}$$

Modelo de Dois Compartimentos



Sistema de EDOs:

$$\begin{aligned}\frac{dC_1}{dt} &= -(k_e + k_{12})C_1 + k_{21}C_2 \\ \frac{dC_2}{dt} &= k_{12}C_1 - k_{21}C_2\end{aligned}$$

Simulação PK: Modelo de Um Compartimento

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.integrate import odeint
4
5 def one_compartment_pk(C, t, ke):
6     """Modelo PK de 1 compartimento"""
7     dCdt = -ke * C
8     return dCdt
9
10 # Parametros
11 ke = 0.2          # constante de eliminacao (1/h)
12 C0 = 100          # concentracao inicial (mg/L)
13 t_half = 0.693 / ke # meia-vida
14
15 # Tempo
16 t = np.linspace(0, 24, 200)
17
18 # Resolver
19 C = odeint(one_compartment_pk, C0, t, args=(ke,))
20
21 # Plotar
22 plt.figure(figsize=(10, 6))
23 plt.plot(t, C, 'b-', linewidth=2, label='[Farmaco]')
24 plt.axhline(y=C0/2, color='r', linestyle='--',
25             label=f't1/2 = {t_half:.2f} h')
26 plt.xlabel('Tempo (horas)')
27 plt.ylabel('Concentracao (mg/L)')
28 plt.title('Farmacocinetica: Modelo 1-Compartimento')
29 plt.legend()
30 plt.grid(True)
```

Listing 1: Farmacocinética monocompartimental

Ensaio Clínicos e Biologia de Sistemas

Fases de Ensaio Clínicos

- **Fase I:** Segurança, farmacocinética (20-100 voluntários)
- **Fase II:** Eficácia preliminar, dose (100-500 pacientes)
- **Fase III:** Eficácia, efeitos adversos (1000-5000 pacientes)
- **Fase IV:** Monitoramento pós-comercialização

Aplicações de Biologia de Sistemas

- **Design de ensaios:** Estratificação de pacientes por perfil molecular
- **Biomarcadores:** Identificação de marcadores de resposta/toxicidade
- **Ensaio *in silico*:** "Digital twins" para prever resultados
- **Adaptive trials:** Ajustes baseados em dados intermediários
- **Análise de subgrupos:** Identificar respondedores vs não-respondedores

Câncer como Doença Sistêmica

Definição: Visão Sistêmica do Câncer

Câncer não é apenas uma doença de um gene mutado, mas resulta de alterações em redes regulatórias, vias de sinalização e interações com o microambiente tumoral.

Características:

- Heterogeneidade genômica
- Plasticidade celular
- Evolução clonal
- Interações com estroma
- Resposta imune
- Metabolismo reprogramado

Níveis de Complexidade:

- Genético: mutações driver/passenger
- Epigenético: metilação, histonas
- Transcriptômico: expressão gênica
- Proteômico: sinalização
- Metabólico: Warburg, glutaminólise
- Microambiente: células imunes, CAFs

Importante!

Abordagens de alvo único falham devido à redundância e plasticidade das redes tumorais

Hallmarks of Cancer

10 Características Essenciais do Câncer (Hanahan & Weinberg)

Características Principais:

1. Sinais de crescimento sustentado
2. Evasão de supressores de crescimento
3. Resistência à morte celular
4. Imortalidade replicativa
5. Angiogênese induzida
6. Invasão e metástase

Características Emergentes:

7. Reprogramação metabólica
8. Evasão imune


Características Facilitadoras:

9. Instabilidade genômica
10. Inflamação promotora de tumor

Implicações Terapêuticas

Cada hallmark representa um alvo terapêutico potencial

Redes Oncogênicas e Supressoras de Tumor



Importante!

Câncer emerge do desequilíbrio entre oncogenes ativados e supressores inativados

Metabolismo do Câncer: Efeito Warburg

Definição: Efeito Warburg

Células cancerosas preferem glicólise aeróbica (menos eficiente) em vez de fosforilação oxidativa, mesmo na presença de oxigênio.

Vantagens para tumor:

- Geração rápida de ATP
- Biomassa (nucleotídeos, lipídios)
- Acidificação do microambiente
- Evasão de apoptose mitocondrial

Reprogramação Metabólica

Vias alteradas:

- ↑ Captação de glicose (GLUT1)
- ↑ Glicólise (HK2, PKM2)
- ↑ Glutaminólise
- ↑ Síntese de lipídios (FASN)
- ↓ OXPHOS


Alvos Metabólicos

- Inibidores de hexoquinase
- Inibidores de LDH-A
- Inibidores de glutaminase

Heterogeneidade Tumoral

Tipos de Heterogeneidade

- **Intratumoral:** diferentes clones no mesmo tumor
- **Intertumoral:** variação entre pacientes
- **Temporal:** evolução durante tratamento
- **Espacial:** gradientes no microambiente



Diferentes clones (C1-C4) têm perfis genômicos distintos
Metástases derivam de clones específicos

Importante!

Heterogeneidade → resistência terapêutica → necessidade de terapias combinadas

Doenças Cardiovasculares como Sistemas

Redes em Doenças Cardiovasculares

Doenças cardiovasculares envolvem interações complexas entre:

- Fatores genéticos (polimorfismos, mutações)
- Metabolismo lipídico (colesterol, triglicerídeos)
- Inflamação (citocinas, células imunes)
- Função endotelial (NO, vasodilatação)
- Coagulação (plaquetas, fatores de coagulação)
- Pressão arterial (RAAS, SNS)

Aterosclerose:

- Acúmulo de LDL oxidado
- Recrutamento de macrófagos
- Formação de células foam
- Placa aterosclerótica
- Inflamação crônica

Abordagens Sistêmicas:

- Identificação de módulos de risco
- Biomarcadores multi-ômicos
- Scores de risco poligênico
- Terapias multi-alvo
- Medicina preventiva personalizada

Diabetes e Síndrome Metabólica

Diabetes Tipo 2: Doença Sistêmica

Componentes interconectados:

- Resistência à insulina (músculo, fígado, tecido adiposo)
- Disfunção de células β pancreáticas
- Metabolismo de glicose alterado
- Lipotoxicidade
- Inflamação crônica de baixo grau
- Estresse oxidativo

Síndrome Metabólica:

1. Obesidade abdominal
2. Hiperglicemia
3. Hipertensão
4. Dislipidemia
5. Estado pró-inflamatório

Modelagem Sistêmica

- Modelos de homeostase glicose-insulina
- Redes de sinalização insulínica
- Integração multi-órgão
- Predição de progressão
- Resposta a intervenções

Doenças Neurodegenerativas

Alzheimer

Características:

- Placas amiloides (β -amiloide)
- Emaranhados neurofibrilares (tau)
- Neuroinflamação
- Perda sináptica
- Disfunção mitocondrial
- Estresse oxidativo

Fatores de risco:

- APOE4 (genético)
- Idade
- Fatores cardiovasculares

Parkinson

Características:

- Perda de neurônios dopaminérgicos
- Corps de Lewy (α -sinucleína)
- Disfunção mitocondrial
- Estresse do RE
- Neuroinflamação

Genes associados:

- SNCA, LRRK2, PARK7
- GBA, PINK1, PARKIN


Importante!

Doenças neurodegenerativas: falha em múltiplos processos celulares → cascata patológica

Módulos de Doença (Disease Modules)

Definição: Módulo de Doença

Conjunto de genes/proteínas topologicamente próximos no interactoma humano cujas perturbações estão associadas a um fenótipo patológico comum.



Aplicações

- Identificação de novos genes de doença
- Compreensão de comorbidades (sobreposição de módulos)
- Reposicionamento de fármacos
- Classificação molecular de doenças

Classificação de Doenças Baseada em Redes

Abordagem Tradicional vs Sistêmica

Critério	Tradicional	Baseada em Rede
Base	Sintomas clínicos	Módulos moleculares
Foco	Órgão/tecido	Vias e redes
Resolução	Baixa	Alta (molecular)
Personalização	Limitada	Alta
Preditiva	Moderada	Alta

Exemplos

- **Câncer:** Classificação por perfil de expressão e mutações (The Cancer Genome Atlas - TCGA)
- **Diabetes:** Subtipos baseados em resistência à insulina vs disfunção de células β
- **Doenças inflamatórias:** Endotipos baseados em perfis de citocinas

Importante!

Doenças com apresentação clínica similar podem ter mecanismos moleculares distintos → requerem tratamentos diferentes

Farmacogenômica

Definição: Farmacogenômica

Estudo de como variações genéticas individuais influenciam a resposta a fármacos, incluindo eficácia e toxicidade.

Fontes de Variabilidade na Resposta a Fármacos

- **Farmacocinética:** variantes em genes ADME (CYP450, transportadores)
- **Farmacodinâmica:** variantes em alvos terapêuticos (receptores, enzimas)
- **Doença:** heterogeneidade molecular da doença
- **Ambiente:** dieta, comorbidades, interações medicamentosas

Objetivos:

- Maximizar eficácia
- Minimizar toxicidade
- Otimizar dose
- Selecionar fármaco adequado

Benefícios

- Medicina personalizada
- Redução de eventos adversos
- Economia de custos
- Melhor adesão

Polimorfismos do Citocromo P450

Família CYP450

Enzimas hepáticas responsáveis pelo metabolismo de 75% dos fármacos

Principais isoformas:

- **CYP2D6:** 25% dos fármacos (antidepressivos, opioides, betabloqueadores)
- **CYP2C9:** warfarina, NSAIDs, hipoglicemiantes
- **CYP2C19:** clopidogrel, IBPs, antidepressivos
- **CYP3A4/5:** 50% dos fármacos (estatinas, imunossupressores)

Fenótipos Metabólicos

Fenótipo	Atividade	Implicação
Poor Metabolizer (PM)	Muito baixa	↑ toxicidade, ↑ dose necessária (pró-fármacos)
Intermediate (IM)	Reduzida	Monitoramento
Normal (NM/EM)	Normal	Dose padrão
Ultra-rapid (UM)	Aumentada	↓ eficácia, ↑ toxicidade (pró-fármacos)

Exemplo: Clopidogrel e CYP2C19

Clopidogrel:


- Pró-fármaco antiagregante
- Previne trombose (pós-stent)
- Requer ativação por CYP2C19

Polimorfismo CYP2C19:

- *1/*1 (EM): metabolizador normal
- *2, *3 (PM): perda de função
- *17 (UM): ganho de função

Importante!

PM têm ↑3x risco de eventos cardiovasculares



Recomendação Clínica:

- PM: usar prasugrel ou ticagrelor (alternativas)
- EM: clopidogrel dose padrão
- UM: monitorar cuidadosamente

Descoberta de Biomarcadores

Tipos de Biomarcadores

- **Diagnóstico:** detectar presença de doença
- **Prognóstico:** prever evolução da doença
- **Preditivo:** prever resposta a terapia
- **Farmacodinâmico:** medir efeito do tratamento
- **Segurança:** detectar toxicidade

Pipeline de Descoberta

1. **Discovery:** análise ômica em larga escala (casos vs controles)
2. **Verificação:** validação em coorte independente
3. **Qualificação:** ensaios prospectivos
4. **Implementação:** testes clínicos validados

Abordagens Sistêmicas:

- Assinaturas multi-gene
- Perfis de proteínas/metabólitos
- Integração multi-ômica

Desafios:

- Reprodutibilidade
- Validação independente
- Padronização de ensaios
- Custo-benefício

Estratificação de Pacientes

Conceito

Classificar pacientes em subgrupos com base em características moleculares, clínicas ou demográficas para tratamento personalizado.

Métodos:

- Clustering (K-means, hierárquico)
- Análise de componentes principais (PCA)
- Non-negative matrix factorization (NMF)
- Machine learning supervisionado
- Network-based stratification

Dados para estratificação:

- Genômicos (mutações, CNVs)
- Transcriptômicos (expressão gênica)
- Proteômicos
- Metabólicos
- Clínicos

Aplicações

- **Ensaio clínico:** enriquecer para respondedores
- **Diagnóstico:** classificar subtipos
- **Prognóstico:** identificar alto vs baixo risco
- **Terapia:** selecionar tratamento ótimo

Importante!

Objetivo: maximizar benefício clínico, minimizar exposição desnecessária a toxicidade

Diagnósticos Baseados em Ômicas

Testes Multi-Ômicos Clínicos

Genômicos:

- Sequenciamento de painel de genes (câncer)
- Whole-exome sequencing (WES)
- Whole-genome sequencing (WGS)
- Liquid biopsy (ctDNA)

Transcriptômicos:

- Oncotype DX (câncer de mama)
- MammaPrint (prognóstico de mama)
- Prosigna (PAM50)

Proteômicos/Metabólicos:

- Painéis de citocinas
- Perfis metabólicos (diabetes, erros inatos)

Vantagens

Informação molecular detalhada → decisões terapêuticas precisas

Subtipos de Câncer de Mama

Classificação Molecular (PAM50)

Baseada em perfil de expressão de 50 genes:

Subtipo	Marcadores	Prognóstico	Tratamento
Luminal A	ER+, PR+, HER2-, Ki67 baixo	Melhor	Hormonioterapia
Luminal B	ER+, HER2+/-, Ki67 alto	Intermediário	Hormônio + quimio
HER2+	ER-, PR-, HER2+	Intermediário	Trastuzumab + quimio
Basal-like	ER-, PR-, HER2- (triplo neg.)	Pior	Quimioterapia

Importante!


Mesmo órgão, histologia similar → diferentes doenças moleculares → tratamentos distintos

Implicação Clínica

Teste de expressão gênica determina:

- Necessidade de quimioterapia adjuvante
- Escolha de terapia-alvo (trastuzumab para HER2+)
- Prognóstico e risco de recorrência

Seleção de Tratamento por Perfil Molecular



Exemplos Clínicos

- **EGFR mutado:** erlotinib/gefitinib (câncer de pulmão)
- **BRAF V600E:** vemurafenib (melanoma)
- **ALK fusão:** crizotinib (câncer de pulmão)
- **BCR-ABL:** imatinib (leucemia mieloide crônica)

Digital Twins e Ensaios Clínicos *In Silico*

Definição: Digital Twin

Réplica computacional personalizada de um paciente individual, baseada em dados multi-ômicos, clínicos e fisiológicos, que permite simular respostas a intervenções terapêuticas.

Componentes:

- Dados do paciente (genoma, transcriptoma, metaboloma, clínicos)
- Modelos mecanísticos (redes, EDOs)
- Parâmetros personalizados
- Simulação computacional

Aplicações:

- Predição de resposta a fármacos
- Otimização de dose
- Identificação de efeitos adversos
- Testes de terapias combinadas

Ensaios *In Silico*

- Testar milhares de cenários rapidamente
- Reduzir necessidade de ensaios animais
- Acelerar desenvolvimento de fármacos
- Stratificação pré-clínica

Desafios

- Validação clínica
- Complexidade dos modelos
- Integração de dados
- Incerteza paramétrica

Desafios em Medicina Personalizada

Desafios Técnicos

- **Integração de dados:** multi-ômicos heterogêneos
- **Interpretação:** variantes de significado incerto (VUS)
- **Validação:** necessidade de estudos prospectivos
- **Padronização:** protocolos laboratoriais e análise
- **Custo:** sequenciamento e análise ainda caros

Desafios Éticos e Sociais

- **Privacidade:** dados genômicos sensíveis
- **Consentimento:** uso de dados, achados incidentais
- **Equidade:** acesso desigual a tecnologias
- **Discriminação:** genética por seguradoras/empregadores
- **Educação:** médicos e pacientes precisam compreender resultados

Importante!

Medicina personalizada requer framework regulatório, ético e de treinamento profissional adequado


Estudo de Caso: Câncer de Mama HER2+ e Trastuzumab

Contexto Clínico

- 15-20% dos cânceres de mama superexpressam HER2
- HER2 (ERBB2): receptor tirosina-quinase
- Superexpressão → proliferação descontrolada
- Prognóstico pior (antes de terapias-alvo)

Trastuzumab (Herceptin):

- Anticorpo monoclonal anti-HER2
- Bloqueia sinalização HER2
- Induz resposta imune (ADCC)
- Primeiro sucesso de medicina personalizada em oncologia



Impacto:

- ↓ 50% mortalidade
- Sobrevida global melhorada
- Usado em adjuvância e metastático

Importante!

Teste HER2 é mandatório em câncer de mama → decisão terapêutica

Doenças Infecciosas: Abordagem Sistêmica

Interações Hospedeiro-Patógeno

Visão sistêmica considera:

- Redes moleculares do patógeno
- Resposta imune do hospedeiro
- Interações proteína-proteína (patógeno-hospedeiro)
- Modulação de vias do hospedeiro por patógeno
- Evolução e adaptação do patógeno

Aplicações:

- Identificação de alvos terapêuticos (essenciais para patógeno)
- Reposicionamento de fármacos
- Previsão de virulência
- Assinaturas de resposta imune
- Estratégias de vacinação

Exemplo: Tuberculose

- Rede metabólica de *M. tuberculosis*
- Identificar enzimas essenciais
- Testar *in silico* inibidores
- Prever resistência a fármacos
- Biomarcadores de progressão latente → ativa

Resistência a Antibióticos como Problema Sistêmico

Mecanismos de Resistência

- Mutações em alvos (RNA polimerase, ribossomo)
- Bombas de efluxo (superexpressão)
- Enzimas inativadoras (β -lactamases)
- Modificação de alvos (metilação de RNA ribossomal)
- Biofilmes (tolerância)

Abordagens Sistêmicas:

- Análise de redes de resistência
- Identificar vulnerabilidades colaterais
- Terapias combinadas racionais
- Predição de evolução de resistência
- Desenvolvimento de novos antibióticos

Estratégias

- **Collateral sensitivity:** resistência a A causa sensibilidade a B
- **Terapias alternadas:** reduzir pressão seletiva
- **Alvos não-essenciais:** virulência sem morte bacteriana
- **Imunomodulação:** fortalecer resposta do hospedeiro

Importante!

Resistência antimicrobiana é uma das maiores ameaças à saúde global

Imunoterapia e Imunologia de Sistemas

Imunoterapia do Câncer

Estratégias que ativam o sistema imune para eliminar células tumorais:

- **Checkpoint inhibitors:** anti-PD-1, anti-CTLA-4 (bloqueiam sinais inibitórios)
- **CAR-T cells:** células T geneticamente modificadas
- **Vacinas terapêuticas:** antígenos tumorais
- **Oncolytic viruses:** vírus que infectam e lisam tumor

Desafios:

- Apenas 20-40% respondem
- Efeitos adversos (autoimunidade)
- Microambiente imunossupressor
- Heterogeneidade tumoral

Imunologia de Sistemas:

- Perfil de infiltrado imune (hot vs cold tumors)
- Assinaturas de resposta
- Carga mutacional tumoral (TMB)
- Expressão de PD-L1
- Modelagem de resposta imune


Importante!

Biomarcadores preditivos são essenciais para selecionar pacientes que se beneficiarão

Terapia com Células CAR-T

Conceito

Células T do paciente são geneticamente modificadas para expressar receptor de antígeno quimérico (CAR) que reconhece antígeno tumoral específico.



Sucessos:

- Leucemias/linfomas B (CD19)
- Taxa de remissão completa >80%
- FDA aprovado (Kymriah, Yescarta)

Modelagem Sistêmica:

- Dinâmica CAR-T vs tumor
- Predição de síndrome de liberação de citocinas (CRS)
- Otimização de dose
- Design de CARs de próxima geração

Design de Vacinas: Abordagem Sistêmica

Vacinologia de Sistemas

Uso de abordagens ômicas e modelagem para:

- Identificar antígenos imunogênicos e protetores
- Prever resposta imune a candidatos vacinais
- Otimizar formulações e adjuvantes
- Estratificar respondedores vs não-respondedores
- Compreender correlatos de proteção

Pipeline:

1. Genômica de patógeno
2. Predição de epítomos (MHC binding)
3. Análise de conservação
4. Teste *in silico* de imunogenicidade
5. Validação experimental
6. Ensaios clínicos

Exemplo: Vacinas mRNA (COVID-19)

- Análise genômica rápida do SARS-CoV-2
- Identificação da proteína Spike (S)
- Design de mRNA otimizado
- Predição de resposta imune
- Desenvolvimento em tempo recorde (<1 ano)

Importante!

Biologia de sistemas acelerou desenvolvimento de vacinas COVID-19

COVID-19 e Resposta de Biologia de Sistemas

Contribuições de Systems Biology na Pandemia

- **Genômica viral:** sequenciamento rápido, rastreamento de variantes
- **Reposicionamento de fármacos:** análise de redes identificou candidatos (remdesivir, dexametasona)
- **Resposta imune:** perfis de citocinas, assinaturas de gravidade (tempestade de citocinas)
- **Interações proteína-proteína:** mapa de interações SARS-CoV-2-humano
- **Modelagem epidemiológica:** previsão de disseminação, impacto de intervenções
- **Vacinas:** design racional (mRNA, vetores virais)

Biomarcadores de Gravidade

- IL-6, D-dímero, ferritina ↑ em casos graves
- Linfopenia, neutrofilia
- Perfis transcriptômicos distinguem progressão

Exemplo: Estratificação de Pacientes com Clustering

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from sklearn.cluster import KMeans
4 from sklearn.preprocessing import StandardScaler
5 from sklearn.decomposition import PCA
6
7 # Dados simulados: pacientes x features (omicas + clinicas)
8 np.random.seed(42)
9 n_patients = 100
10 data = np.random.randn(n_patients, 10) # 10 features
11
12 # Normalizar
13 scaler = StandardScaler()
14 data_scaled = scaler.fit_transform(data)
15
16 # Clustering K-means
17 kmeans = KMeans(n_clusters=3, random_state=42)
18 clusters = kmeans.fit_predict(data_scaled)
19
20 # PCA para visualizacao
21 pca = PCA(n_components=2)
22 data_pca = pca.transform(data_scaled)
23
24 # Plotar
25 plt.figure(figsize=(8, 6))
26 scatter = plt.scatter(data_pca[:, 0], data_pca[:, 1],
27                       c=clusters, cmap='viridis', s=50)
28 plt.xlabel('PC1')
29 plt.ylabel('PC2')
30 plt.title('Estratificacao de Pacientes (K-means)')
31 plt.colorbar(scatter, label='Cluster')
32 plt.legend(['Subgrupo 1', 'Subgrupo 2', 'Subgrupo 3'])
```

Listing 2: Análise de clusters em dados clínicos

Exercícios - Parte 1: Farmacocinética

Questão 1: Modelo PK

Um paciente recebe dose IV bolus de 500 mg de um fármaco. O volume de distribuição é $V_d = 50$ L e a meia-vida é $t_{1/2} = 4$ h.

1. Calcule a constante de eliminação k_e
2. Calcule o clearance (CL)
3. Qual será a concentração após 8 horas?
4. Calcule a AUC (área sob a curva)

Questão 2: Modelo de Dois Compartimentos

Implemente um modelo farmacocinético de dois compartimentos em Python e simule a concentração ao longo de 24 horas. Use os seguintes parâmetros:

- $k_e = 0.15 \text{ h}^{-1}$, $k_{12} = 0.3 \text{ h}^{-1}$, $k_{21} = 0.2 \text{ h}^{-1}$
- Dose = 1000 mg IV, $C_1(0) = 20 \text{ mg/L}$, $C_2(0) = 0$

Exercícios - Parte 2: Redes de Doenças

Questão 3: Análise de Rede DTI

Dado o seguinte grafo bipartido de interações fármaco-alvo:

- Fármaco A: alvos T1, T2, T3
 - Fármaco B: alvos T2, T4
 - Fármaco C: alvos T3, T4, T5
1. Construa a matriz de adjacência
 2. Calcule o grau de promiscuidade de cada fármaco
 3. Identifique alvos compartilhados (potencial para efeitos adversos similares)
 4. Sugira reposicionamento de fármacos baseado em sobreposição de alvos

Questão 4: Módulos de Doença

Use algoritmo de Louvain ou Girvan-Newman para detectar módulos em uma rede de interações proteína-proteína associada a doença cardiovascular. Interprete os módulos funcionalmente.

Exercícios - Parte 3: Medicina Personalizada

Questão 5: Farmacogenômica

Um paciente é metabolizador pobre (PM) de CYP2D6 e recebe codeína (pró-fármaco convertido em morfina por CYP2D6).

1. Preveja o efeito no manejo da dor
2. Qual ajuste de dose ou medicação alternativa você recomendaria?
3. Como você explicaria ao paciente a importância do teste farmacogenômico?

Questão 6: Estratificação de Pacientes

Implemente clustering K-means em um dataset de expressão gênica de câncer de mama (use dataset público como TCGA ou simulado). Identifique subgrupos moleculares e compare com subtipos clínicos conhecidos (Luminal A/B, HER2+, Basal).

Projeto Prático: Análise de Dados Clínicos Ômicos

Projeto Integrador

Objetivo: Analisar dados multi-ômicos de pacientes com câncer para identificar biomarcadores e estratificar pacientes.

Etapas:

1. **Dados:** Baixar dados de expressão gênica e clínicos (TCGA, GEO, cBioPortal)
2. **Pré-processamento:** Normalização, controle de qualidade, filtro de variância
3. **Análise exploratória:** PCA, heatmaps, clustering hierárquico
4. **Clustering:** K-means ou NMF para identificar subgrupos
5. **Biomarcadores:** Análise diferencial (DESeq2, limma) entre subgrupos
6. **Sobrevida:** Curvas de Kaplan-Meier, teste log-rank
7. **Validação:** Dataset independente
8. **Interpretação biológica:** Enriquecimento funcional (GO, KEGG)

Entregável: Relatório com código Python/R, figuras e interpretação clínica

Referências Principais

-  Barabási A.L., Gulbahce N., Loscalzo J. (2011). *Network medicine: a network-based approach to human disease*. Nature Reviews Genetics 12:56-68.
-  Auffray C., Chen Z., Hood L. (2009). *Systems medicine: the future of medical genomics and healthcare*. Genome Medicine 1:2.
-  Schadt E.E. (2009). *Molecular networks as sensors and drivers of common human diseases*. Nature 461:218-223.
-  Zhou X., Menche J., Barabási A.L., Sharma A. (2014). *Human symptoms-disease network*. Nature Communications 5:4212.
-  Hanahan D., Weinberg R.A. (2011). *Hallmarks of cancer: the next generation*. Cell 144:646-674.

Referências: Network Medicine e Farmacologia

-  Hopkins A.L. (2008). *Network pharmacology: the next paradigm in drug discovery*. Nature Chemical Biology 4:682-690.
-  Zhao S., Iyengar R. (2012). *Systems pharmacology: network analysis to identify multiscale mechanisms of drug action*. Annual Review of Pharmacology and Toxicology 52:505-521.
-  Csermely P., Korcsmáros T., Kiss H.J., et al. (2013). *Structure and dynamics of molecular networks: a novel paradigm of drug discovery*. Pharmacology & Therapeutics 138:333-408.
-  Menche J., Sharma A., Kitsak M., et al. (2015). *Disease networks: uncovering disease-disease relationships through the incomplete interactome*. Science 347:1257601.

Referências: Medicina Personalizada e Ômicas

-  Ashley E.A. (2016). *Towards precision medicine*. Nature Reviews Genetics 17:507-522.
-  Roden D.M., McLeod H.L., Relling M.V., et al. (2019). *Pharmacogenomics*. The Lancet 394:521-532.
-  Chen R., Snyder M. (2013). *Promise of personalized omics to precision medicine*. Wiley Interdisciplinary Reviews: Systems Biology and Medicine 5:73-82.
-  Brunet J.P., et al. (2004). *Metagenes and molecular pattern discovery using matrix factorization*. PNAS 101:4164-4169.

Bases de Dados Clínicas e Farmacogenômicas

- **DrugBank:** <https://go.drugbank.com> — fármacos, alvos, PK/PD
- **TCGA:** <https://portal.gdc.cancer.gov> — dados multi-ômicos de câncer
- **UK Biobank:** <https://www.ukbiobank.ac.uk> — dados de saúde populacional
- **ClinVar:** <https://www.ncbi.nlm.nih.gov/clinvar> — variantes clínicas
- **PharmGKB:** <https://www.pharmgkb.org> — farmacogenômica

Ferramentas de Análise

- **cBioPortal:** <https://www.cbioportal.org> — análise de dados de câncer
- **STRING:** <https://string-db.org> — interações proteína-proteína
- **Cytoscape:** <https://cytoscape.org> — visualização de redes
- **GSEA:** <https://www.gsea-msigdb.org> — enriquecimento funcional

Livros e Reviews

- Loscalzo J., Barabási A.L., Silverman E.K. (2017). *Network Medicine: Complex Systems in Human Disease and Therapeutics*. Harvard University Press.
- Zhu H., Xia M. (2016). *Advances in Systems Biology*. Springer.
- Wolkenhauer O. (2013). *Systems Medicine*. Springer.

Artigos de Revisão Importantes

- Hood L., Friend S.H. (2011). *Predictive, personalized, preventive, participatory (P4) cancer medicine*. Nature Reviews Clinical Oncology 8:184-187.
- Ideker T., Krogan N.J. (2012). *Differential network biology*. Molecular Systems Biology 8:565.
- Califano A., Alvarez M.J. (2017). *The recurrent architecture of tumour initiation, progression and drug sensitivity*. Nature Reviews Cancer 17:116-130.

Obrigado!

Capítulo 13: Systems Biology in Medicine

Tópicos Abordados:

Descoberta de fármacos · Doenças complexas

Medicina personalizada · Aplicações clínicas

Dúvidas? Perguntas?

A medicina do futuro é sistêmica, preditiva, personalizada e participativa