

Capítulo 15: Emerging Topics

Bioinformática para Biologia de Sistemas

Ney Lemke

DBF-Unesp

3 de janeiro de 2026

Sumário

- 1 Introdução
- 2 Modelagem Multi-Escala
- 3 Biologia de Sistemas de Célula Única
- 4 Inteligência Artificial em Biologia de Sistemas
- 5 Doenças Complexas e Envelhecimento
- 6 Direções Futuras
- 7 Exercícios
- 8 Referências

Visão Geral do Capítulo


Objetivos de Aprendizagem

- Explorar tópicos emergentes em biologia de sistemas
- Compreender modelagem multi-escala
- Conhecer análise de célula única e transcriptômica espacial
- Aprender sobre inteligência artificial aplicada à biologia
- Discutir doenças complexas, envelhecimento e medicina de precisão
- Vislumbrar direções futuras da área

Importante!

Este é o capítulo final do curso, onde integramos conhecimentos anteriores e olhamos para o futuro da biologia de sistemas!

Evolução Rápida da Biologia de Sistemas



Tendências Atuais

- Integração de múltiplas camadas ômicas
- Resolução de célula única e espacial
- Modelagem multi-escala (molécula → organismo)
- IA para descoberta e predição
- Medicina personalizada e digital twins

15.1 Modelagem Multi-Escala

Definição: Modelagem Multi-Escala


Integração de modelos computacionais em diferentes níveis de organização biológica: molecular, celular, tecidual, órgão e organismo completo.

Desafios da Integração Multi-Escala

1. **Escala temporal:** ms (cinética enzimática) → anos (envelhecimento)
2. **Escala espacial:** nm (proteínas) → m (organismo)
3. **Complexidade:** 10^{12} moléculas → trilhões de células
4. **Heterogeneidade:** variabilidade celular e individual
5. **Computação:** custo proibitivo de simulações completas

Importante!

Hierarquia Multi-Escala



Exemplo: Metabolismo da Glicose

Modelos Baseados em Agentes (ABM)

Definição: Agent-Based Model

Modelo computacional onde entidades autônomas (agentes) seguem regras simples, e comportamentos complexos emergem das interações.

Características:

- Agentes autônomos
- Regras locais simples
- Interações entre agentes
- Ambiente compartilhado
- Emergência de padrões

Aplicações:

- Crescimento tumoral
- Resposta imune
- Morfogênese
- Dinâmica de populações
- Epidemiologia

Exemplo: Tumor

Cada célula é um agente que pode: proliferar, migrar, morrer, ou entrar em quiescência

Exemplo Simples de ABM em Python


```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 class Cell:
5     """Agente representando uma celula"""
6     def __init__(self, x, y, cell_type='normal'):
7         self.x = x
8         self.y = y
9         self.type = cell_type
10        self.alive = True
11
12    def proliferate(self, environment):
13        """Celula pode proliferar se houver espaco"""
14        if environment.nutrient_level[self.x, self.y] > 0.5:
15            # Criar celula filha adjacente
16            new_x = self.x + np.random.randint(-1, 2)
17            new_y = self.y + np.random.randint(-1, 2)
```


Modelos Híbridos: Discreto + Contínuo

Abordagem Híbrida

Combina modelos discretos (células individuais) com modelos contínuos (difusão de nutrientes, fatores de crescimento).

Agentes discretos (células)



Órgãos Virtuais e Fisiologia de Corpo Inteiro

Órgãos Virtuais:

- Coração virtual (eletrof.)
- Fígado virtual (metabolismo)
- Pulmão virtual (ventilação)
- Rim virtual (filtração)



Projetos Internacionais:

- Virtual Physiological Human
- Physiome Project
- Human Brain Project

Desafio

Integrar dinâmicas de múltiplos órgãos acoplados!

Exemplo: Metabolismo Hepático Multi-Escala

Níveis Integrados

1. **Molecular:** cinética de enzimas (CYP450, glicoquinase)
2. **Celular:** hepatócitos individuais (zonas periportal/pericentral)
3. **Lobular:** gradiente de O_2 e nutrientes
4. **Órgão:** fluxo sanguíneo, metabolismo sistêmico
5. **Organismo:** regulação hormonal (insulina, glucagon)

Modelagem

- ODEs para metabolismo celular
- PDEs para difusão espacial
- ABM para heterogeneidade hepatócito
- Controle sistêmico (feedback hormonal)

15.2 Biologia de Sistemas de Célula Única

Revolução da Célula Única

Tecnologias que permitem medir milhares de moléculas em células individuais, revelando heterogeneidade antes invisível.

Técnicas Principais:

- scRNA-seq
- scATAC-seq (cromatina)
- scProteomics (CyTOF)
- scMetabolomics
- Multi-omic single-cell


Aplicações:

- Descoberta de tipos celulares
- Trajetórias de diferenciação
- Heterogeneidade tumoral
- Desenvolvimento embrionário
- Resposta imune

Importante!

A célula única é a unidade fundamental da vida. Tecidos aparentemente homogêneos

Single-Cell RNA-seq (scRNA-seq)



Droplet-based
(10x Genomics)

Identificação de Tipos Celulares e Clustering

Pipeline de Análise scRNA-seq

1. **Controle de qualidade:** remover células de baixa qualidade
2. **Normalização:** corrigir profundidade de sequenciamento
3. **Seleção de genes:** genes altamente variáveis
4. **Redução de dimensionalidade:** PCA, UMAP, t-SNE
5. **Clustering:** Louvain, Leiden
6. **Anotação:** marcadores conhecidos

Ferramentas

- **Scanpy** (Python)
- **Seurat** (R)
- **Monocle** (trajectories)

Análise scRNA-seq com Scanpy

```
1 import scanpy as sc
2 import numpy as np
3
4 # Carregar dados
5 adata = sc.read_10x_mtx('filtered_feature_bc_matrix/')
6
7 # QC: filtrar células e genes
8 sc.pp.filter_cells(adata, min_genes=200)
9 sc.pp.filter_genes(adata, min_cells=3)
10
11 # Calcular % mitocondriais
12 adata.var['mt'] = adata.var_names.str.startswith('MT-')
13 sc.pp.calculate_qc_metrics(
14     adata, qc_vars=['mt'], inplace=True
15 )
16
17 # Filtrar células ruins
```


Clustering e Visualização

```
1 # Construir grafo de vizinhos
2 sc.pp.neighbors(adata, n_neighbors=10, n_pcs=40)
3
4 # Clustering com algoritmo Leiden
5 sc.tl.leiden(adata, resolution=0.5)
6
7 # UMAP para visualizacao
8 sc.tl.umap(adata)
9
10 # Plotar
11 sc.pl.umap(adata, color=['leiden', 'n_genes'])
12
13 # Encontrar genes marcadores
14 sc.tl.rank_genes_groups(adata, 'leiden', method='wilcoxon')
15 sc.pl.rank_genes_groups(adata, n_genes=20, sharey=False)
16
17 # Anotar clusters manualmente
```


Pseudotempo e Inferência de Trajetórias

Definição: Pseudotempo

Ordem inferida de células ao longo de um processo dinâmico (diferenciação, ativação) baseada em similaridade transcricional.



Transcriptômica Espacial

Resolvendo a Localização

scRNA-seq perde informação espacial. Novas tecnologias preservam contexto espacial:

Tecnologias:

- **Visium** (10x): arrays espaciais
- **MERFISH**: imaging baseado em FISH
- **seqFISH+**: multiplexado
- **Slide-seq**: beads espaciais
- **Stereo-seq**: ultra-alta resolução

Aplicações:

- Arquitetura tecidual
- Microambiente tumoral
- Organização cerebral
- Nicho de células-tronco
- Desenvolvimento embrionário


Importante!

Combina melhor dos dois mundos: expressão gênica detalhada + localização espacial!

Comunicação Célula-Célula

Inferindo Interações

Análise de pares ligante-receptor para identificar comunicação entre tipos celulares.



Ferramentas

- CellPhoneDB
- NicheNet
- CellChat
- LIANA

15.3 IA em Biologia de Sistemas

A Revolução da IA

Machine learning e deep learning estão transformando a biologia de sistemas, permitindo análise de dados massivos e descoberta de padrões complexos.

Machine Learning:

- Supervisionado (classificação)
- Não-supervisionado (clustering)
- Reforço (otimização)
- Ensemble methods


Deep Learning:

- Redes neurais profundas
- CNNs (imagens)
- RNNs/Transformers (sequências)
- GNNs (grafos/redes)
- GANs (geração)

Importante!

IA não substitui modelagem mecanística, mas complementa: híbrido é o futuro!

Aprendizado Profundo para Dados Biológicos



Aplicações:

- Predição de expressão gênica
- Classificação de tipos celulares
- Predição de estrutura proteica (AlphaFold)
- Design de drogas

Rede Neural para Classificação

```
1 import torch
2 import torch.nn as nn
3 import torch.optim as optim
4
5 class GeneExpressionClassifier(nn.Module):
6     """Rede neural para classificar amostras"""
7     def __init__(self, input_dim, hidden_dim, output_dim):
8         super().__init__()
9         self.fc1 = nn.Linear(input_dim, hidden_dim)
10        self.relu = nn.ReLU()
11        self.dropout = nn.Dropout(0.3)
12        self.fc2 = nn.Linear(hidden_dim, hidden_dim // 2)
13        self.fc3 = nn.Linear(hidden_dim // 2, output_dim)
14        self.softmax = nn.Softmax(dim=1)
15
16    def forward(self, x):
17        x = self.fc1(x)
```


Graph Neural Networks (GNNs)

Definição: GNN

Redes neurais que operam diretamente em grafos, aprendendo representações de nós e arestas. Ideais para redes biológicas!

Aplicações:

- Predição de função de proteínas
- Descoberta de drogas
- Propriedades moleculares
- Redes regulatórias
- Interações proteína-proteína



Modelos: GCN, GraphSAGE, GAT, Message Passing NN

GNN Básico para Rede Molecular

```
1 import torch
2 from torch_geometric.nn import GCNConv, global_mean_pool
3
4 class MolecularGNN(torch.nn.Module):
5     """GNN para predicacao de propriedades moleculares"""
6     def __init__(self, num_features, hidden_dim, num_classes):
7         super().__init__()
8         self.conv1 = GCNConv(num_features, hidden_dim)
9         self.conv2 = GCNConv(hidden_dim, hidden_dim)
10        self.conv3 = GCNConv(hidden_dim, hidden_dim)
11        self.fc = torch.nn.Linear(hidden_dim, num_classes)
12
13    def forward(self, x, edge_index, batch):
14        # Node embeddings
15        x = self.conv1(x, edge_index)
16        x = torch.relu(x)
17        x = self.conv2(x, edge_index)
```


Transformers e AlphaFold

Mecanismo de Atenção

Transformers usam "attention" para capturar dependências de longo alcance em sequências.

AlphaFold 2 (DeepMind, 2020)

- Revolucionou predição de estrutura proteica
- Precisão próxima a estruturas experimentais
- Baseia-se em: transformers + MSA + embeddings estruturais
- Predisse estrutura de >200M proteínas (AlphaFold DB)

Importante!

AlphaFold é um dos maiores sucessos de IA em biologia!


Modelos Generativos: Design de Moléculas

Generative Models:

- **VAE:** Variational Autoencoder
- **GAN:** Generative Adversarial Network
- **Diffusion:** Diffusion models
- **RL:** Reinforcement learning

Aplicações:

- Design de proteínas
- Design de drogas (SMILES)
- Otimização de anticorpos



Exemplo

MegaMolBART (transformers) gera moléculas drug-like otimizadas

IA Interpretável e Explicável

Importante!

Modelos de caixa-preta são problemáticos em biologia e medicina!

Abordagens para Interpretabilidade

1. **Feature importance:** quais genes são mais importantes?
2. **SHAP values:** contribuição de cada feature
3. **Attention maps:** o que o modelo está "olhando"
4. **Layer-wise relevance propagation (LRP)**
5. **Modelos híbridos:** integrar conhecimento biológico


Inferência Causal vs Correlação

- **Correlação:** *A e B variam juntos*


15.4 Doenças Complexas como Perturbações de Rede

Abordagem de Network Medicine

Doenças complexas (câncer, diabetes, Alzheimer) não resultam de defeito em gene único, mas de perturbações em redes moleculares.



Saudável



Doença

Nós vermelhos: genes mutados/desregulados

Propagação: perturbação se espalha pela rede

Multi-Omics para Envelhecimento

Hallmarks of Aging:

1. Instabilidade genômica
2. Atrito de telômeros
3. Alterações epigenéticas
4. Perda de proteostase
5. Senescência celular
6. Disfunção mitocondrial
7. Desregulação nutricional
8. Exaustão de células-tronco
9. Comunicação intercelular alterada

Abordagem Multi-Omic:

- Genômica (mutações)
- Epigenômica (metilação)
- Transcriptômica (expressão)
- Proteômica (proteostase)
- Metabolômica (NAD⁺, etc.)


Relógios Epigenéticos

DNA methylation age: preditor de idade biológica (Horvath clock)

Vias de Longevidade

Pathways Conservados

Vias moleculares que modulam longevidade em múltiplas espécies:




Intervenções:

- Restrição calórica

Comorbidity Networks

Grafos representando co-ocorrência de doenças em populações, revelando mecanismos compartilhados.



Insight: diabetes mellitus tipo 2 (DM2) é hub central

Aplicação: priorizar intervenções, prever risco

Sistemas para Preparação Pandêmica

Importante!

COVID-19 demonstrou necessidade de biologia de sistemas para resposta rápida!

Abordagens Sistêmicas

1. **Vigilância genômica:** sequenciamento em tempo real de variantes
2. **Modelos epidemiológicos:** previsão de disseminação (SIR, SEIR)
3. **Multi-omics de hospedeiro:** identificar fatores de risco
4. **Drug repurposing:** IA para identificar drogas existentes
5. **Design de vacinas:** epitopos computacionais
6. **Network medicine:** entender síndrome pós-COVID

Lição: integração de dados heterogêneos + modelos + infraestrutura computacional


Medicina de Precisão: Futuro

De População para Indivíduo:

- Genoma pessoal (WGS)
- Multi-omics longitudinal
- Microbioma
- Wearables (monitoramento)
- Histórico médico completo

Desafios:

- Custo
- Interpretação clínica
- Privacidade
- Equidade de acesso



15.5 Direções Futuras

O Futuro da Biologia de Sistemas


A área está em rápida evolução. Várias tecnologias e abordagens prometem revolucionar nossa compreensão da vida.

Tecnologias Emergentes:

- Laboratórios automatizados
- Plataformas robóticas
- Microfluídica
- Organoides e organs-on-chip
- Edição genômica (CRISPR)
- Biologia sintética

Computação:

- Computação quântica
- Edge computing
- Federated learning
- Blockchain para dados
- Cloud-based pipelines



Vantagens:

- Experimentos 24/7
- Alta reprodutibilidade
- Exploração massiva do espaço de parâmetros
- Loop fechado: IA propõe experimentos → robô executa → análise → nova hipótese

Exemplos: Emerald Cloud Lab, Strateos, Ada (Carnegie Mellon)

Geração de Hipóteses por IA

IA Criativa

Sistemas de IA que não apenas analisam dados, mas propõem novas hipóteses biológicas testáveis.

Abordagens


1. **Mineração de literatura:** extrair relações de milhões de papers
2. **Knowledge graphs:** raciocínio sobre entidades e relações
3. **Reinforcement learning:** explorar espaço de experimentos
4. **Generative models:** propor novas moléculas, vias
5. **Causal inference:** identificar relações causais

Importante!

Digital Twins para Medicina Personalizada

Definição: Digital Twin

Réplica computacional dinâmica de um paciente individual, integrando dados multi-omics, fisiológicos e clínicos em tempo real.



Computação Quântica para Simulação Biológica

Computação Quântica

Computadores quânticos exploram superposição e entrelaçamento para resolver problemas intratáveis classicamente.

Aplicações Potenciais em Biologia:

1. **Simulação quântica de moléculas:** dinâmica eletrônica precisa
2. **Folding de proteínas:** explorar espaço conformacional exponencial
3. **Drug discovery:** otimização combinatorial
4. **Análise de grafos:** redes biológicas massivas
5. **Machine learning quântico:** aceleração de algoritmos

Realidade Atual

Ainda estamos na era NISQ (Noisy Intermediate-Scale Quantum). Aplicações práticas em biologia ainda distantes, mas pesquisa ativa!

Integração de Microbioma e Fatores Ambientais

Importante!

O hospedeiro não pode ser estudado isoladamente: microbioma e ambiente são partes integrantes do sistema!

Microbioma:

- 10× mais células que humanas
- Metabolismo complementar
- Modulação imune
- Eixo intestino-cérebro
- Resistência a patógenos

Metagenômica:

- 16S rRNA-seq (taxonomia)

Exposoma:

- Dieta
- Poluentes
- Estresse
- Atividade física
- Sono
- Medicamentos

Holobionte

Movimento Open Science

Transparência, reprodutibilidade e acesso aberto são cruciais para acelerar descobertas.

Princípios FAIR:

- Findable: dados encontráveis
- Accessible: acessíveis
- Interoperable: interoperáveis
- Reusable: reutilizáveis

Recursos:

- Repositórios públicos (GEO, SRA, PDB, etc.)
- Pré-prints (bioRxiv, medRxiv)
- Código aberto (GitHub)
- Notebooks reprodutíveis (Jupyter)
- Protocolos detalhados (protocols.io)

Considerações Éticas

Questões Éticas Emergentes

1. **Privacidade:** genomas pessoais, re-identificação
2. **Consentimento informado:** uso secundário de dados
3. **Equidade:** acesso a tecnologias avançadas (precision medicine gap)
4. **Viés algorítmico:** datasets não-representativos
5. **Edição germline:** CRISPR em embriões
6. **Biologia sintética:** biossegurança, dual use
7. **Propriedade intelectual:** patentes de genes, dados

Importante!

Cientistas têm responsabilidade de considerar implicações sociais de seu trabalho!

Exercícios - Parte 1

Questão 1: Modelagem Multi-Escala

Descreva como você modelaria o metabolismo da glicose integrando os níveis:

1. Molecular (cinética de hexoquinase)
2. Celular (hepatócito)
3. Órgão (fígado)

Quais são os principais desafios de acoplamento entre escalas?

Questão 2: Single-Cell RNA-seq

Dado um dataset scRNA-seq de um tumor:

1. Como você identificaria diferentes tipos celulares?
2. Como inferiria comunicação entre células tumorais e células imunes?
3. Qual a importância da informação espacial?

Questão 3: Machine Learning

1. Quando usar modelos de ML vs. modelos mecânicos?
2. Explique o problema de interpretabilidade em redes neurais profundas.
3. Como você validaria um modelo de ML para predição clínica?

Projeto Prático

Escolha um tópico emergente (célula única, IA, envelhecimento) e:

1. Revise a literatura recente (últimos 2 anos)
2. Identifique um dataset público relevante
3. Aplique pelo menos uma técnica computacional
4. Gere visualizações e interprete resultados
5. Discuta limitações e direções futuras

Referências Principais

-  Jumper J. et al. (2021). Highly accurate protein structure prediction with AlphaFold. *Nature*.
-  Wolf F.A. et al. (2018). SCANPY: large-scale single-cell gene expression data analysis. *Genome Biology*.
-  López-Otín C. et al. (2023). Hallmarks of aging: An expanding universe. *Cell*.
-  Barabási A.L. et al. (2011). Network medicine: a network-based approach to human disease. *Nature Reviews Genetics*.
-  Moses C. et al. (2021). Museum of spatial transcriptomics. *Nature Methods*.

Artigos de Revisão Recentes

- Integrative multi-omics approaches (Nature Reviews, 2023)
- Single-cell multi-omics technologies (Nature Biotechnology, 2023)
- AI for drug discovery (Nature Machine Intelligence, 2024)
- Digital twins in healthcare (Nature Medicine, 2023)
- Longevity and healthspan interventions (Cell, 2023)

Recursos Online

- **AlphaFold DB:** <https://alphafold.ebi.ac.uk>
- **Single Cell Portal:** <https://singlecell.broadinstitute.org>
- **Human Cell Atlas:** <https://www.humancellatlas.org>
- **PyTorch Geometric:** <https://pytorch-geometric.readthedocs.io>

Obrigado!

Capítulo 15: Emerging Topics

Conclusão do Curso

Este curso cobriu desde fundamentos de sistemas biológicos até os tópicos mais avançados e emergentes da biologia de sistemas. Vocês agora têm as ferramentas conceituais e computacionais para:

- Modelar sistemas biológicos em múltiplos níveis
- Analisar dados omics em larga escala
- Integrar conhecimento multi-escala e multi-omic
- Aplicar IA e aprendizado de máquina
- Contribuir para o futuro da medicina de precisão